

제 143회 석사학위논문

지도교수 전 웅 선

교차로 도로변 센서 시스템을 위한
강화학습 기반의 단안 카메라와 2D 라이다
센서 융합 알고리즘

Reinforcement Learning-Based Sensor Fusion of
Monocular Camera with 2D LiDAR
for Roadside Sensor System at a Intersection

중앙대학교 대학원

전자전기공학과 전자전기공학전공

곽 민 재

2025년 8월

교차로 도로변 센서 시스템을 위한
강화학습 기반의 단안 카메라와 2D 라이다
센서 융합 알고리즘

Reinforcement Learning-Based Sensor Fusion of
Monocular Camera with 2D LiDAR
for Roadside Sensor System at a Intersection

이 논문을 석사학위논문으로 제출함

2025년 8월

중앙대학교 대학원

전자전기공학과 전자전기공학전공

곽 민 재

곽민재의 석사학위논문으로 인정함

심사위원장 심 덕 선 ①인

심 사 위 원 이 정 룬 ①인

심 사 위 원 전 웅 선 ①인

중앙대학교 대학원

2025년 8월

목 차

제 1 장 서 론	1
1.1 연구의 배경	1
1.2 연구의 목적	9
제 2 장 차량 탐지	10
제 3 장 DQN과 IMM 기반의 차량 추적 프레임 워크	13
3.1 제안하는 프레임워크 개요	13
3.2 센서 융합 전략 선택을 위한 DQN	14
3.3 IMM 기반 차량 움직임 추정	24
제 4 장 결 과	34
4.1 시뮬레이션 환경 구성	34

4.1.1	라이다 탐지 포인트 구성	34
4.1.2	바운딩 박스 생성	36
4.1.3	차량 운동 및 제어 시뮬레이션	37
4.2	단일/다중 차량 추적 시뮬레이션 결과	40
4.3	마할라노비스 거리 기반 방법과 심층 강화학습 방법 비교분석	49
4.4	센서 시스템	57
4.5	단일/다중 차량 추적 현장 실험 결과	59
제 5 장	결 론	72
참 고 문 헌		74
부 록		80
국 문 초 록		84
ABSTRACT		86

<표 목차>

Table 1 시뮬레이션 환경에서 제안된 방법의 성능 평가	48
Table 2 현장 실험에 사용된 센서의 세부 사양	58
Table 3 현장 실험 환경에서 제안된 방법의 성능 평가	71
[부록] Table 4 DQN 하이퍼 파라미터	80
[부록] Table 5 DQN 신경망 구조	80
[부록] Table 6 시뮬레이션 환경에서의 공분산 행렬 R 설정값	81
[부록] Table 7 시뮬레이션 환경에서의 공분산 행렬 Q 설정값	81
[부록] Table 8 현장 실험 환경에서의 공분산 행렬 R 설정값	82
[부록] Table 9 현장 실험 환경에서의 공분산 행렬 Q 설정값	82

<그림 목차>

Fig. 1 YOLO와 DBSCAN 기반의 차량 탐지 알고리즘 흐름도	12
Fig. 2 차량 모서리 추정을 위한 센서 융합 방법	14
Fig. 3 제안 프레임워크	20
Fig. 4 DQN 기반 센서 융합을 위한 상태 벡터	21
Fig. 5 라이다 탐지점 분류	36
Fig. 6 시뮬레이션에서 캡처된 프레임	39
Fig. 7 단일 차량 좌회전 시뮬레이션 결과	40 41 42
Fig. 8 단일 차량 직진 시뮬레이션 결과	43 44
Fig. 9 다중 차량 시나리오의 시뮬레이션 결과	45 46 47
Fig. 10 시나리오별 마할라노비스 거리 기반 방법과 제안 알고리즘의 행동 선택 비교 결과	51
Fig. 11 차량의 급가속-감속 시나리오 결과	53
Fig. 12 차량간 가림 현상 시나리오	54
Fig. 13 차량간 가림 현상 시나리오 결과	55 56
Fig. 14 삼각대 기반 2D 라이다 및 단안 카메라 센서 플랫폼	57
Fig. 15 서울시 강서구 마곡동 현장 실험 대상지 모습	59
Fig. 16 차량 루프 중앙에 설치된 GPS 안테나	60
Fig. 17 삼각대 기반 센서 플랫폼을 이용하여 촬영한 현장 실험 이미지	61
Fig. 18 현장 실험 이미지에 대응하는 라이다 포인트 데이터	61
Fig. 19 단일 차량 좌회전 현장 실험 결과	62 63 64
Fig. 20 단일 차량 직진 현장 실험 결과	65 66 67
Fig. 21 다중 차량 시나리오의 현장 실험 결과	68 69 70

제 1 장 서 론

1.1 연구의 배경

교차로는 구조적인 설계 특성상 다수의 잠재적 충돌 지점을 형성하여 고속도로에 비해 상대적으로 높은 사고 위험을 유발한다[1]. 또한 도시 교통망의 핵심 노드로서 다양한 방향에서 차량이 동시에 합류하고 분기함으로써 교통 흐름이 복잡해지고, 충돌 위험 또한 증가한다. 미국 도로교통안전국 (National Highway Traffic Safety Administration, NHTSA)의 2022년 보고서에 따르면, 미국 내 차량 충돌사고의 약 49%가 교차로에서 발생한 것으로 나타났다[2]. 또한, 미국 연방도로청 (Federal Highway Administration, FHWA)의 조사 결과에서도 2022년 전체 교통사고 사망자의 28.3%에 해당하는 12,036명이 교차로 사고로 인해 사망하였다고 보고된 바 있다[3]. 국내에서도 2023년 한국도로교통공단 자료에 따르면, 교차로에서의 사고 비율(48.3%)이 단일 도로에서의 사고 비율 (43.6%)보다 높게 나타났다[4].

이러한 통계적 근거는 교차로가 다른 도로 환경에 비해 교통사고 발생 및 치사율이 상대적으로 높다는 것을 명확히 보여준다. 특히 이러한 높은 위험성은 교차로에서 발생하는 복잡한 차량 간 상호작용과 운전자들의 제한된 시야에서 기인한다. 따라서 교차로에서의 차량 추적 (vehicle tracking)은 단순히 차량 이동을 모니터링하는 것을 넘어, 충돌 위험을 예방하고 향후에는 교통 흐름의 최적화의 기반으로 확장될 수 있다.

최근 교차로에서의 차량 추적 정확도 향상 방안으로 도로변 센서 시스템 (roadside sensor system)이 연구되고 있다[5]-[7]. 도로변 센서 시스템은 지정된 구역 내 차량의 위치와 이동 경로를 실시간으로 모니터링할 수 있게 해주며, 이를 통해 보다 정밀한 차량 추적 및 위치 추정이 가능해진다.

도로변 센서를 활용한 차량 추적에 관한 최근 연구는 특히 고 해상도 센싱 능력을 지닌 3D 라이다 (LiDAR) 및 카메라 기반 시스템에 집중되고 있다[9]-[13]. 이들 시스템은 뛰어난 감지 성능을 통해 차량 탐지 정확성을 향상시키는 데 기여하고 있다.

3D 라이다는 높은 정밀도의 공간 측정이 가능하여 차량의 정확한 위치 추정과 움직임 예측에 강점이 있다. 3D 라이다를 이용한 차량 탐지 기법은 일반적으로 포인트 클라우드를 기반으로 한 세그멘테이션, 클러스터링, 특징 추출 등의 과정을 거치며, 이를 통해 차량과 주변 환경을 효과적으로 구분한다. 특히, 3차원 동적 공간 필터링 (3D Dynamic Spatial Filtering, DSF)과 밀도 기반 공간 군집 알고리즘 (Density-Based Spatial Clustering of Applications with Noise, DBSCAN)은 포인트 클라우드에서 차량 후보군을 배경 잡음과 효과적으로 분리하는 역할을 수행한다[7]. 이후, 탐지된 차량의 형태 및 방향성을 정교화하기 위해 L-shape fitting 방법이 활용되며, 베이지안 의사결정 이론 (Bayesian Decision Theory, BDT)을 통해 차량 탐지의 정확도를 추가로 향상시킬 수 있다[8]. 또한, 탐지된 객체를 차량과 비차량으로 정확하게 구분하기 위해 서포트 벡터 머신(Support Vector Machines, SVM), 랜덤 포레스트 (Random Forest, RF)와 같은 머신러닝 기반 기법이 적용되고 있다[9]. 최근에는 더욱 정밀한 바운딩 박스

(bounding box) 추정을 위해 역전파 인공 신경망 (Backpropagation Artificial Neural Networks, BP-ANN)과 같은 딥러닝 모델을 활용하여 차량 탐지 정확성을 향상시키는 연구가 진행되고 있다[10].

한편, 카메라 기반 접근법은 풍부한 시각적 정보를 제공하기 때문에 차량의 상세한 인식 및 분류에 유리하다. 이러한 방법은 다양한 이미지 처리 기법과 딥러닝 모델을 결합하여 정확한 차량 탐지를 수행한다. 예를 들어, 배경 차분과 Sobel edge 검출 기법을 결합하여 차량의 움직임을 효과적으로 검출하는 방법[6]이나, 배경 업데이트 기법을 적용하여 움직이는 차량을 정적으로 존재하는 배경과 구분하는 접근법[11] 등이 제안되고 있다. 최근 연구에서는 YOLOv3[12], YOLOX[13]와 같은 딥러닝 기반의 실시간 객체 인식 및 추적 모델이 높은 탐지 정확도와 신속성을 보이며, 카메라 기반 차량 탐지 시스템의 성능을 크게 향상시키고 있다.

차량 탐지 기술이 각 프레임 내에서 차량의 위치를 식별하고 객체를 분류하는 역할을 수행한다면, 추적 기술은 연속된 여러 프레임에 걸쳐 탐지된 차량을 동일한 객체로 연관 지어 시간에 따라 일관된 궤적을 형성한다. 이를 통해 차량의 위치와 속도를 지속적으로 추정할 수 있게 해주며, 이는 교통 환경과 같이 동적으로 변화하는 상황에서 차량의 정확한 움직임 예측을 위해 필수적이다.

라이다와 카메라 기반의 차량 추적 기법은 모두 주로 칼만 필터를 기반으로 차량의 위치와 속도를 추정하며, 시간에 따른 차량 궤적을 예측한다[12]. 3D 라이다 기반 추적에서는 일반적으로 기본 칼만 필터[8], [10] 외에도 비선형성 처리가 가능한 무향

칼만 필터 (unscented Kalman filter, UKF)와 다중 객체 환경에서 데이터 연관성 문제를 해결할 수 있는 JPDAF (Joint Probabilistic Data Association Filter)와 같은 고급 필터링 기법이 활용된다[9]. 또한, 전역 최근접 이웃(Global Nearest Neighbor, GNN)과 같은 데이터 연관성 기법을 적용하여 서로 다른 프레임 사이에서 탐지된 객체 간의 연속성을 유지하고 추적의 정확성을 향상시킨다[7].

카메라 기반 추적 방식에서도 일반적으로 칼만 필터가 차량의 움직임을 예측하고, 시간에 따른 객체 궤적을 추정하는 데 널리 활용된다. 대표적으로 SORT (Simple Online and Realtime Tracker)는 탐지를 통한 추적 프레임워크를 기반으로 칼만 필터를 활용하여 차량의 위치와 속도를 지속적으로 갱신한다[12]. 이 접근법을 발전시킨 Bot-SORT는 객체의 외형 특징을 추출하는 재식별 (Re-Identification, ReID) 네트워크를 추가로 적용하여 객체 간의 연결성을 강화하며, 추적 관계 테이블과 칼만 필터의 간소화된 형태인 α - β 필터를 결합하여 차량 위치와 속도의 추정치를 정밀하게 보정 한다[6], [13].

라이다 기반 추적 방법은 높은 비용과 많은 연산량이 필요하다는 점에서 도심 교차로와 같은 대규모 환경에 적용할 때 확장성의 한계를 가진다. 반면, 카메라 기반 추적 방법은 직접적인 거리 정보가 없어 위치와 속도 그리고 각도 추정에 어려움을 겪는 한계를 나타낸다.

이러한 단일 센서 시스템의 한계를 극복하고, 각 센서의 장점을 결합하고자 센서 융합 (sensor fusion)이 연구가 진행되고 있다. 특히 대규모로 적용하기에 지나치게 고가인 고성능 3D 라이

다 센서 대신, 상대적으로 저렴한 저해상도 라이다와 단안 카메라 (monocular camera)를 결합하여 비용과 성능의 균형을 맞추는 접근이 제안되고 있다[14], [15]. 이러한 융합 접근법은 라이다의 정밀한 거리 측정 능력과 카메라가 제공하는 풍부한 시각 정보를 결합하여 다양한 환경에서 안정적이고 정확한 차량 추적이 가능하게 한다. 또한 과도한 재정적 부담 없이 교외 지역, 농촌 지역 등과 같은 다양한 도로 환경 및 예산이 제한된 교차로 환경에서도 보편적으로 활용할 수 있다는 점에서 그 실용성을 높여준다.

센서 융합의 이점을 극대화하기 위해 최근 연구에서는 딥러닝과 규칙 기반 (rule-based) 접근 등 다양한 기술을 활용하여 multi-modal 센서 데이터를 통합하고 있다. 특히 최근 연구들은 2D 이미지 특징과 3D 포인트 클라우드 데이터를 효율적으로 결합하기 위한 다양한 방법을 제안하고 있다. Complexer-YOLO 모델은 카메라의 시맨틱 세그멘테이션과 라이다 포인트 클라우드를 격자 형태로 변환하여 결합해 객체 탐지 및 추적 성능을 실시간으로 향상시키고자 하였다[16]. 또 다른 연구인 BEVEFNet은 카메라 이미지와 LiDAR 데이터를 다단계로 융합하여 Bird's Eye View (BEV) 공간에서 통합적으로 표현하여 객체 추적의 정확도를 높였다[17].

한편, 보셀화된 포인트 클라우드를 활용한 Complexer-YOLO나 BEV 공간 기반의 다단계 융합 방식을 채택한 BEVEFNet과 달리, 최근 제안된 JMODT (Joint Multi-Object Detection and Tracking) 프레임워크는 다중 스케일의 포인트 단위 특징 융합을 통해 서로 다른 센서에서 얻은 특징들을 여러 공간 해상도에 결

쳐 정렬 및 통합하여 통합된 객체 표현을 생성한다. 이러한 통합 표현 방식은 객체 식별 일관성을 유지하는 재식별 (Re-Identification, Re-ID) 특징을 활용하여 프레임 간 객체 추적의 정확성을 높이고, 3D 거리 기반 IoU (Distance-IoU, DIoU)를 사용한 연관도 계산을 통해 객체 간의 연관성을 정교화한다. 또한, MIP (Mixed-Integer Programming) 기반의 데이터 연관성 기법을 통해 탐지된 객체를 기존 궤적과 최적화된 방식으로 연결하여 더욱 견고하고 연속적인 차량 추적을 가능하게 한다[18]. 그러나 이러한 접근 방식은 대규모 데이터 수집에 따른 비용과 시간이 많이 소요되고, 방대한 데이터셋과 높은 연산 자원을 필요로 한다는 현실적인 제약을 지니고 있다.

딥러닝 기반 센서 융합 기법 외에도, 규칙 기반 접근법들은 서로 다른 센서로부터 탐지된 객체들 간의 중복도를 측정하는 IoU (Intersection over Union) 임계 값을 이용해 센서 데이터를 연관시켜 바운딩 박스의 중심을 기준으로 객체를 추적한다. 대표적으로, 특정한 높은 3D IoU 임계값을 초과하는 센서별 탐지 객체들을 우선적으로 결합한 뒤, IoU 값이 미리 설정된 중간 범위에 있을 경우 마할라노비스 거리 (Mahalanobis distance)를 활용하여 탐지 객체와 기존 추적 경로 간의 통계적 유사성을 검증한다. 마지막으로, 이 과정에서 매칭되지 않은 객체들은 이미지 도메인에서의 2D IoU를 통해 다시 한번 연관성을 평가하여 추적의 일관성을 높이며, 최종적으로 매칭된 객체들은 바운딩 박스의 중심좌표를 상태 예측의 기준으로 삼아 칼만 필터를 통해 궤적을 갱신한다[19]. 더욱 발전된 접근법으로는 각 센서로부터 얻은 2D와 3D 바운딩 박스를 융합하기 위해 IoU와 신뢰도 (confidence

score)를 동시에 고려하는 방식이 제안되었다. 이 방법에서는 IoU가 일정 기준을 초과한 객체들을 칼만 필터와 헝가리안 매칭(Hungarian matching)을 활용해 추적함으로써 탐지의 강건성을 향상시킨다[20]. 그러나 이러한 규칙 기반 방법들은 센서 간 탐지 결과가 불일치하거나, 차량이 회전하는 경우처럼 바운딩 박스의 정렬이 어긋나는 상황에서는 신뢰성이 급격히 떨어질 수 있다. 이러한 한계를 극복하기 위해 먼 거리에서는 2D 추적을 수행하다가 IoU 임계값에 따라 차량이 센서에 가까워지면 3D 추적으로 전환하는 방식도 제안된 바 있으나[21], 이 또한 동적 환경에 대한 강건성 측면에서 도전과제가 남아 있다.

한편, 규칙 기반 기법은 데이터 연관 방식뿐만 아니라 차량 추적 시 기준점을 설정하는 방식에 따라서도 구분된다. 대표적으로 바운딩 박스 내에서 센서와 가장 가까운 점을 기준점으로 선정하는 방식[22]과 L-shape fitting 기반 방식[23]으로 구분될 수 있다. 다만, 센서에서 가장 가까운 점을 선택하는 방식은 차량의 방향이 변하거나 차량 간 가림 현상이 발생할 때 추적의 일관성이 크게 저하되는 단점이 있다. 또한 L-shape fitting 방식의 경우 라이다가 차량 정면만을 관측할 때는 평면적이고 기하학적 특징이 거의 없는 윤곽선만 얻을 수 있어 전면에서 접근하는 차량을 정확히 탐지하는데 한계가 있으며, 차량 간 가림이나 관측 각도의 변화에 따라 명확한 L자 형태를 추출하는 것도 어려워진다. 이러한 연구들은 센서 데이터의 복잡도가 높아질수록 사전에 정의된 규칙만으로는 효과적으로 대응하기 어렵고, 성능 저하로 이어질 수 있다.

이를 해결하기 위해 본 연구에서는 강화학습 기반의 센서 용

합 방식을 제안하고자 한다. 규칙 기반이나 모델 기반의 접근 방식은 불확실성이 높은 상황에서 효과적으로 대응하기 어렵다. 반면, 강화학습은 환경에 따라 적응성을 높이고, 사전에 정의된 고정된 규칙에 대한 의존도를 낮춰 강건성과 유연성을 높일 수 있다. 또한 강화학습은 대규모의 데이터셋이나 많은 계산 자원을 사용하지 않고도 효율적으로 센서 융합 전략을 학습할 수 있다.

1.2 연구의 목적

본 연구는 도로변 센서 시스템을 활용한 차량 추적 성능을 개선하기 위해 새로운 강화학습 기반 센서 융합 기법을 제안하고자 한다. 기존의 단일 센서 기반 추적 방법과 정적인 규칙 기반 센서 융합 방식은 다양한 교차로 상황 및 각 센서의 특성을 유연하게 반영하지 못하여 성능 저하의 한계가 존재한다. 이를 극복하기 위해 본 연구에서는 교차로 환경에서 저비용의 2D 라이다와 단안 카메라를 결합한 센서 시스템을 구축하고, 실시간으로 가장 적합한 센서 융합 전략을 선택할 수 있는 심층 강화학습 기반 프레임워크를 개발하고자 한다. 또한, IMM (Interacting Multiple Model) 필터와 다양한 차량 이동 모델을 통합하여 차량의 위치, 속도, 방향 등 차량 상태를 보다 정확히 추정할 수 있도록 한다. 이를 위해 실제 교차로 상황을 반영한 시뮬레이션 환경 및 데이터셋을 구현하여, 다양한 현실적 시나리오를 통해 강화학습 모델을 훈련하고자 한다. 이후 학습한 모델에 대해 실제 현장 실험을 통해 제안한 기법의 실용성과 실효성을 검증하고자 한다.

제 2 장 차량 탐지

제 2 장에서는 단안 카메라 (monocular camera)와 2D 라이다의 데이터를 통합적으로 활용하여 시각적 정보와 공간 정보를 결합함으로써 차량을 정확하고 강건하게 탐지하는 차량 탐지 알고리즘을 제안한다.

우선, 카메라 영상을 입력으로 받은 YOLO는 차량으로 추정되는 객체의 방위각 범위를 설정한다. 동시에, 라이다에서 획득된 데이터 포인트들에 대해 밀도 기반 군집화 알고리즘 (DBSCAN)을 적용하여 공간적으로 밀집된 포인트들은 하나의 클러스터로 묶고, 밀도가 낮은 고립된 포인트는 잡음으로 분류한다[24]. 이 과정에서 DBSCAN의 매개변수인 반경과 최소 포인트 수를 적절하게 설정함으로써 다양한 환경 및 포인트 밀도 조건에서도 강건한 차량 탐지가 가능해진다. 본 연구에서는 최소 포인트 수를 2개로 설정하였으며, 이는 저해상도 라이다 데이터 특성상 차량이 소수의 포인트로 탐지되는 현실적인 상황을 반영한 것이다. 또한 차량 탐지 알고리즘 이후 적용되는 RANSAC (Random Sample Consensus) 알고리즘이 선 모델을 생성하기 위해 요구하는 최소 포인트 수가 2개임을 고려하여, 클러스터링 결과가 후속 RANSAC 선 모델 생성 단계에 활용될 수 있도록 설정하였다.

DBSCAN이 적용된 후, 각 클러스터에 대해 다음의 4가지 상황으로 분류한다.

- (1) YOLO로 측정된 방위각 내에 한 개의 클러스터만 있는 경우
- (2) 클러스터가 YOLO로 측정된 방위각 내에 없는 경우

- (3) 방위각 범위 내에 여러 클러스터가 존재하는 경우
- (4) 클러스터가 생성되지 않고, 방위각 내에 라이다 포인트가 한 개만 있는 경우

먼저, YOLO로 측정된 방위각 내에 클러스터가 한 개만 존재하는 경우 이를 차량으로 판단한다. 반대로 YOLO로 측정된 방위각 내에 클러스터가 존재하지 않으면 차량이 아닌 것으로 판단한다. 방위각 내에 여러 개의 클러스터가 존재하거나 방위각 내에 라이다 포인트가 단 한 개만 존재하는 경우에는 다음 두 가지 추가 단계를 진행한다.

첫 번째 단계로, 각 클러스터 포인트와 센서 간 거리의 평균값을 계산한다. 해당 클러스터에 속한 모든 포인트에 대해 라이다 센서로부터 떨어진 유클리드 거리 (Euclidean distance)의 평균값을 $d_{m,curr}$ 로 정의하고, 이를 다음과 같이 계산한다.

$$d_{m,curr} = \frac{1}{N} \sum_{i=1}^N d_i \quad (4)$$

여기서 N 은 클러스터에 포함된 포인트의 수이며, d_i 는 클러스터 내 각 포인트와 센서 간의 거리를 나타낸다. 두 번째로, 이전 프레임에서 계산된 평균 거리 $d_{m,prev}$ 가 존재할 경우, 다음과 같은 조건으로 현재 평균 거릿값이 이전 프레임에서 계산된 평균 거리와 ± 1 미터 이내인지 확인한다.

$$|d_{m,curr} - d_{m,prev}| \leq 1m \quad (5)$$

두 거릿값의 차이가 $\pm 1m$ 이내일 때 동일 객체로 간주하고 차량 존재한다고 판단한다.

이러한 방식으로 YOLO의 시각적 탐지 성능과 라이다의 정밀한

거리 측정 능력을 결합함으로써 다양한 환경에서도 안정적이고 신뢰성 있는 차량 탐지가 가능하다. 앞서 설명한 YOLO 방위각과 라이다 클러스터 수에 따른 차량 탐지 분류는 Fig. 1과 같다.




Fig. 1 YOLO 방위각과 라이다 클러스터 수에 따른 차량 탐지 분류

제 3 장 DQN과 IMM 기반의 차량 추적 프레임워크

제 3 장에서는 DQN과 IMM 기반의 차량 추적 프레임워크를 설명하였다. 본 프레임워크는 DQN을 통해 실시간으로 최적의 센서 융합 전략을 선택하고, IMM 필터를 이용하여 차량 상태를 강건하게 추정하는 구조를 갖는다. 구체적으로, 3.1절에서는 프레임워크의 개요를 설명하고, 3.2절에서는 DQN의 상태 벡터 구성, 동적 센서 융합 전략의 선택 과정, 그리고 학습 방법을 상세히 설명하였다. 마지막으로, 3.3절에서는 IMM 필터를 활용하여 차량 움직임을 추정하는 방법을 다루었다.

3.1 제안하는 프레임워크 개요

본 연구에서 제안하는 프레임워크는 DQN (Deep Q-Network)를 활용하여 매 시점마다 가장 적합한 센서 융합 전략을 동적으로 선택하는 구조를 갖는다. 구체적으로 DQN은 ϵ -greedy 정책을 기반으로 각 시점에서 최적의 센서 융합 방법을 학습하며, 선택된 방법의 출력 결과를 상호작용 다중 모델 IMM 필터의 측정 입력으로 활용한다. IMM 필터는 여러 가지 차량 운동 모델을 결합하여 차량 상태를 강건하게 추정하는 역할을 수행한다. 이러한 방식으로 구성된 본 프레임워크는 센서 데이터의 변화 및 다양한 환경 조건에 적응할 수 있어, 궁극적으로 차량 위치 추정의 정확성을 향상시킨다. 제안한 프레임워크의 전체 구조와 구성요소 간의 상호작용은 Fig. 2에 나타내었다.




Fig. 2 제안 프레임워크

3.2 센서 융합 전략 선택을 위한 DQN

본 연구는 DQN를 활용하여 센서 융합 전략의 가치함수를 학습하고, 실시간으로 현재의 센서 환경에 가장 적합한 센서 조합을 선택하는 방법을 제안한다.

본 연구에서 제안하는 DQN은 센서 융합 전략을 결정하는 과정을 마르코프 결정 과정 (Markov Decision Process, MDP)으로 모델링하며, 현재 센서 데이터를 상태 (state)로 표현하고 가능한 모든 센서 융합 조합을 행동 (action) 공간으로 정의한다.

DQN 에이전트 (agent)는 상태 s 에서 행동 a 를 선택함으로써

얻을 수 있는 누적 보상의 기댓값을 나타내는 최적의 행동 가치 함수 $Q^*(s, a)$ 을 근사한다. 이를 위해 매개변수 θ 를 가진 심층 신경망 (deep neural network) $Q(s, a; \theta)$ 를 사용하며, 시간차 (Temporal Difference, TD) 학습법을 통해 네트워크를 훈련한다. 훈련 과정의 안정성을 높이기 위해 별도의 타겟 네트워크 (target network) $Q(s, a; \theta_{target})$ 를 유지하고, 일정 주기마다 메인 네트워크로부터 파라미터 θ 를 복사하여 갱신한다 ($\theta_{target} \leftarrow \theta$). 또한, 학습을 위한 과거 경험 데이터를 저장하는 재생 메모리 버퍼 (replay memory buffer) B 를 크기 N 으로 설정하며, 학습률 (learning rate) $\alpha < 0$, 할인 인자 (discount factor) $\gamma \in [0, 1]$, 탐색률 (exploration rate) ϵ 및 탐색률 감쇠를 정의하여 학습을 진행한다. 각 에피소드 $m = 1, \dots, M$ 시작 시 환경을 초기화한 후, 에이전트는 총 T 개의 시간 단계 (time step)에 걸쳐 환경과 상호작용을 한다. 여기서 T 는 차량 경로의 전체 길이를 나타낸다.

구체적으로, DQN의 상태 벡터는 실시간 센서 측정 데이터를 기반으로 추출한 다음의 7가지 파라미터로 구성된다

- (1) 가장 가까운 횡방향 포인트: 라이다에서 탐지된 가장 가까운 횡방향 (lateral) 포인트의 (x, y) 좌표
- (2) 가장 먼 종방향 포인트 : 라이다에서 탐지된 가장 먼 종방향 (longitudinal) 포인트의 (x, y) 좌표
- (3) 가장 가까운 종방향 포인트 : 라이다에서 탐지된 가장 가까운 종방향 포인트의 (x, y) 좌표
- (4) YOLO 최대 방위각 차이 (최대-기준 최소): 현재 프레임의 최대 방위각 (a_{max})과 기준 프레임의 최소 방위각 ($a_{min, ref}$) 간의 차이로, 초기 기준 대비 차량 방위각 최대 변화량

- (5) YOLO 최소 방위각 기준 차이 (최소-기준 최소): 현재 프레임의 최소 방위각 (a_{min})과 기준 프레임의 최소 방위각 ($a_{min,ref}$) 간의 차이로, 방위각 측정값 정규화를 위한 기준값
- (6) 탐지 라이다 포인트 개수: 라이다 클러스터 내에서 탐지된 라이다 포인트 수
- (7) 라이다 포인트 평균 거리: 라이다 클러스터 내 모든 유효 포인트의 평균 거리

특히, 파라미터 4번과 5번은 YOLO의 초기(기준) 최소 방위각 ($a_{min,ref}$)을 기준으로 방위각 측정값을 정규화하여 센서의 변동과 관계없이 차량의 상대적 방향 변화를 일관되게 포착한다. 위에서 언급한 7개의 파라미터는 Fig. 3에 도식적으로 나타내었다.




Fig. 3 DQN 기반 센서 융합을 위한 상태 벡터

프레임별 탐지 결과에만 의존할 경우, 차량의 가림, 센서 노이즈 (sensor noise), 차량의 다양한 자세 변화 등으로 인해 지속적이고 강건한 추적이 어렵다는 한계가 존재한다. 따라서 본 연구는 이러한 문제를 해결하기 위해 차량의 전방 우측 모서리를 고정된 참조 점으로 지정하여 차량 위치의 종방향 및 횡방향 정보를 일관되게 유지하도록 하였다.

이를 바탕으로 본 연구에서는 RANSAC, YOLO 및 IMM 예측 정보를 결합하여 차량 위치 추정 정확성을 향상시키는 위한 다섯 가지의 센서 융합 방식을 행동 (action)으로 정의하고, DQN을 통해 각 프레임마다 실시간으로 최적의 센서 융합 전략을 선택하는 방법을 제안한다.

센서 융합 과정의 세부 절차는 다음과 같다. 먼저 차량으로 탐지된 라이다 포인트 클러스터 전체를 대상으로 RANSAC 알고리즘을 적용하여 초기 선 모델을 생성하며, 이 과정에서 데이터 포인트는 내점 (inlier)과 외점 (outlier)으로 구분된다. 이후 내점과 외점에 대해 각각 별도의 RANSAC 피팅을 수행하여 총 세 가지 선 모델 후보군을 형성한다: (1) 전체 포인트 대상 모델, (2) 내점 기반 모델, (3) 외점 기반 모델. 각 모델은 평균 제곱근 오차(RMSE)를 기준으로 평가한다.

평가 결과, 내점 기반 모델과 외점 기반 모델의 RMSE 합이 전체 포인트 대상 모델의 RMSE (Root Mean Squared Error)보다 작은 경우 두 개의 독립적인 선 모델 (내점 기반 모델과 외점 기반 모델)을 선택하며, 그렇지 않을 경우에는 단일 선 모델 (전체 포인트 대상 모델)을 사용한다.

두 개의 선 모델이 채택된 경우, 첫 번째 방법인 ‘RANSAC 교

차점'은 독립적으로 도출된 두 개의 RANSAC 선 모델 간의 교차점을 차량 전방 우측 모서리 위치로 추정한다. 이때, 두 선의 교차 각이 설정된 최소 임계값 이상이어야만 유효한 교차점으로 인정되며, 거의 평행한 두 선에서 발생할 수 있는 잘못된 교차점을 방지한다.

두 번째 및 세 번째 방법은 각각 'YOLO 최대 방위각과 RANSAC 선 모델의 교차점' (방법 2)과 'YOLO 최소 방위각과 RANSAC 선 모델의 교차점' (방법 3)이다. 두 방법 모두 차량의 전방 우측 모서리 위치를 추정하기 위한 센서 융합 후보점을 생성하며, 사용 가능한 RANSAC 선 모델의 개수에 따라 다음과 같이 구분하여 진행된다.

(1) 두 개의 RANSAC 선 모델이 선택된 경우

각 YOLO 방위각 경계선 (최대 또는 최소)과 두 개의 RANSAC 선 모델 간 교차점을 계산하여 방법당 최대 두 개의 교차점을 도출한다. 이후 각 교차점에서 센서 원점까지의 거리를 평가하여 라이다 클러스터 내 실제 측정 포인트보다 더 가까운 교차점은 이상치로 간주하여 제거한다. 제거 이후 남은 유효 교차점 개수에 따라 다음 절차를 통해 최종 후보 점을 결정한다.

- 유효한 교차점이 두 개인 경우: 센서에서 더 가까운 교차점을 최종 후보점으로 선택한다.
- 유효한 교차점이 하나인 경우: 두 RANSAC 선 간 교차 각도를 평가하여 그 값이 $30^{\circ} \sim 100^{\circ}$ 사이일 때만 최종 후보점으로 인정한다.
- 유효 교차점이 없거나, 교차 각도 조건을 만족하지 못한 경우: 데이터 포인트 수가 더 많은 RANSAC 선과 해당 YOLO 경계선 간

의 교차점을 최종 후보점으로 선택한다.

(2) 단일 RANSAC 선 모델이 선택된 경우

전체 라이다 포인트를 이용해 생성한 단일 RANSAC 선 모델과 YOLO의 최대 및 최소 방위각 경계선 간의 교차점을 각각 계산하여 방법 2와 방법 3의 후보 점을 직접 결정한다.

이와 같은 절차를 통해 각 방법은 독립적으로 하나의 후보점을 제공하며, 이 후보 점들은 차량의 전방 우측 모서리 위치를 정밀하게 추정하기 위한 센서 융합 후보군으로 활용된다.

네 번째 방법인 ‘횡방향 가장 가까운 점’은 센서 원점에서 측정된 횡방향 거리 (lateral distance)가 최소인 라이다 포인트를 차량 모서리 위치로 직접 사용하며, 차량 회전 시 안정적인 물리적 기준점을 제공한다.

다섯 번째 방법인 ‘IMM 예측 점’은 IMM 필터를 활용한 시간적 예측 기반 방법으로, 전 단계 (step $k-1$)에서 차량 상태 정보를 이용하여 일정 속도 모델과 선회운동 모델을 확률적으로 결합하여 현재 단계 (step k)의 차량 위치를 예측한 값 ($\hat{x}_{k|k-1}, \hat{y}_{k|k-1}$)을 사용한다. 현재 단계 (step k)의 센서 입력이 불안정하거나 부재한 경우에도 이전 단계의 예측 결과를 통해 안정적이고 연속적인 차량 위치 추적이 가능하다.

본 연구에서 제안하는 다섯 가지 센서 융합 방법은 유효한 RANSAC 선 모델의 개수 및 YOLO의 방위각 경계선 존재 여부에 따라 동적으로 결정된다. Fig. 4는 각 센서 융합 방법을 요약하여 나타낸 것이다.




Fig. 4 차량 모서리 추정을 위한 센서 융합 방법

각 시간 단계 t 에서의 행동 a_t 는 식 (5)과 같은 ϵ -greedy 정책에 따라 선택된다.

$$a_t = \begin{cases} \text{random action,} & \text{with probability } \epsilon \\ \arg\max_a Q(s_t, a; \theta), & \text{otherwise} \end{cases} \quad (6)$$

각 선택된 행동은 이전에 정의한 센서 융합 전략과 일대일로 연결된다. 선택된 행동이 환경에서 수행되면, 그 결과로 다음 상태 s_{t+1} , 보상 r_t , 종료 여부 d_t 가 결정된다. 이 과정에서 생성된 전이 튜플 $(s_t, a_t, r_t, s_{t+1}, d_t)$ 은 재생 메모리 버퍼 B 에 저장된다. 이후 DQN 파라미터들을 학습할 때, 버퍼 B 로부터 전이 튜플의 미니 배치(mini-batch) $b = (s_j, a_j, r_j, s'_j, d_j)_{j=1}$ 를 샘플링한다. 미니 배치에 속한 각 샘플에 대해 목표 Q 값 (target Q-value) y_j 는 다음과 같이 벨만 방정식 (Bellman equation)을 기반하여 계산된다.

$$y_j = \begin{cases} r_j & \text{if } d_j = 1(\text{terminal}) \\ r_j + \gamma \max_a Q(s'_j, a_j; \theta_{target}), & \text{otherwise} \end{cases} \quad (7)$$

여기서, γ 는 미래 보상의 중요도를 조절하는 할인 인자이며, θ_{target} 는 타겟 네트워크 (target network)의 파라미터를 나타낸다.

손실 함수 (loss function)는 목표 Q 값 y_j 와 현재 Q 네트워크가 예측한 Q 값 $Q(s_j, a_j; \theta)$ 사이의 평균 제곱 오차 (mean squared error, MSE)로 정의된다.

$$L(\theta) = \frac{1}{N_b} \sum_{j=1}^{N_b} (y_j - Q(s_j, a_j; \theta))^2 \quad (8)$$

여기서 N_b 는 배치크기 (batch size)를 나타낸다. Q 네트워크는 위 손실 함수 $L(\theta)$ 를 최소화하도록 경사 하강법 (gradient descent)를 통해 파라미터 θ 를 업데이트한다.

$$\theta \leftarrow \theta - \alpha \cdot \nabla_{\theta} L(\theta) \quad (9)$$

타겟 네트워크의 파라미터 θ_{target} 는 한 에피소드가 끝날 때마다 메인 네트워크의 파라미터와 기존 타겟 네트워크의 파라미터를 혼합하는 소프트 업데이트 (soft update)를 통해 주기적으로 갱신된다. 소프트 업데이트 방식을 통해 타겟 네트워크의 파라미터를 점진적으로 갱신함으로써 학습 과정의 안정성을 높이고 Q 값의 급격한 변화를 방지하고자 하였다. 이 과정은 다음과 같은 식으로 나타낼 수 있다.

$$\theta_{target} \leftarrow \tau \theta + (1 - \tau) \theta_{target} \quad (10)$$

여기서, $\tau \in (0, 1)$ 는 소프트 업데이트의 비율을 결정하는 매개 변수이다. 또한 탐색 파라미터 ϵ 은 버퍼가 일정 수준 이상 채워

진 시점부터, epsilon 값을 매 에피소드마다 일정한 비율로 감소시키는 지수적 감쇠 (exponential decay) 방식을 사용하여, 탐색 (exploration) 중심에서 활용 (exploitation) 중심의 정책으로 점진적으로 전환되도록 설계하였다. 지수적 감쇠 방식은 다음과 같은 식으로 나타낼 수 있다.

$$\epsilon_t = \epsilon_0 \cdot (\epsilon_{decay})^m \quad (11)$$

여기서 ϵ_t 는 에피소드 m 에서의 탐색률, ϵ_0 는 초기 탐색률, ϵ_{decay} 는 감소율을 나타낸다. 각 시간 단계 t 에서의 보상 r_t 는 선택된 행동, 즉, 선택된 센서 융합 방법에 따른 위치와 실제 차량 우측 전방 코너점 간의 거리에 따라 계산된다. 이를 위해, 다수의 행동 후보 집합 $\{a^{(1)}, a^{(2)}, a^{(3)}, a^{(4)}, a^{(5)}\}$ 중에서 실제 위치 P_{true} 까지의 유클리드 거리 (Euclidean distance)를 계산하여 다음과 같이 정의한다.

$$d_i = \sqrt{(x_{a^{(i)}} - x_{true})^2 + (y_{a^{(i)}} - y_{true})^2} \quad (12)$$

여기서,

$$i \in \{1, 2, 3, 4, 5\}$$

이 거릿값들은 집합 $D = \{d_1, d_2, d_3, d_4, d_5\}$ 을 구성한다. 여기서 d_{min} 은 D 에서 가장 작은 거리이고, $d_{second\ min}$ 은 두 번째로 작은 거리이다. 각 시간 단계 t 에서의 보상 r_t 은 다음과 같이 정의한다.

$$r_t = \begin{cases} 10, & \text{if } d_{selected} = d_{min} \\ 5, & \text{if } d_{selected} = d_{second\ min} \\ 0, & \text{otherwise} \end{cases} \quad (13)$$

여기서, $d_{selected}$ 는 실제로 DQN이 선택한 행동의 위치와 실제 위치 간의 유클리드 거리이다. 이러한 보상 설계는 에이전트 하

여금 실제 차량 위치와의 오차를 최소화하는 센서 융합 전략을 선택하도록 유도하며, 결과적으로 전체적인 위치 추정 정확도를 향상할 수 있다.

3.3 IMM 기반 차량 움직임 추정

앞서 소개한 것과 같이 센서 융합 방법은 여러 가지가 있으며, 본 연구에서는 ϵ -greedy 정책을 기반으로 Q-값을 통해 최적의 센서 융합 방법을 선택한다. 그러나 최적의 융합 전략을 사용하더라도 센서 데이터는 제한된 해상도, 지연 시간, 외부 환경 방해와 같은 요인으로 인해 노이즈가 발생할 수 있다. 이를 해결하기 위해 칼만 필터를 사용하여 센서 측정값의 불확실성을 보완하여 차량의 움직임을 추정한다. 그러나 단일 움직임 모델을 기반으로 하는 칼만 필터는 직선 주행과 회전 주행이 빈번히 전환되는 실제 차량의 다양한 움직임을 충분히 표현할 수 없다. 따라서 이러한 동적인 환경에서의 추정 정확도를 높이기 위해 본 연구에서는 선형 모델과 회전 모델을 모두 고려한 움직임 추정 프로세스를 적용한다. 이 모델들은 상호작용 다중 모델 (Interacting Multiple Model, IMM) 필터[25]를 통해 확률적으로 결합하여 연속적이고 신뢰할 수 있는 상태 추정을 제공한다.

IMM 필터는 차량의 복합적인 움직임을 효과적으로 포착하기 위해 여러 움직임 모델을 각각의 확률에 따라 결합한다. IMM 필터는 크게 세 가지 단계로 작동한다. 모델 간 혼합 단계 (interaction), 모드별 필터링 (mode-matched filtering), 그리고 최종

결합 (combination) 단계이다. 우선 상호작용 단계에서는 이전 시점 $k-1$ 의 모든 모델로부터 얻어진 상태 추정값 $\hat{x}_{i,k-1|k-1}$ 과 공분산 $P_{i,k-1|k-1}$ 을 모드 전환 확률 p_{ij} 와 모드 확률 $\mu_{i,k-1}$ 을 이용하여 결합함으로써, 다음 시점 k 의 각 모델 j 에 대한 혼합 초기 조건을 계산한다. 이때, 혼합 확률 $\mu_{i|j,k-1|k-1}$ 은 다음과 같이 계산된다.

$$\mu_{i|j,k-1|k-1} = \frac{p_{ij}\mu_{i,k-1}}{\sum_{i=1}^m p_{ij}\mu_{i,k-1}} \quad (14)$$

여기서 p_{ij} 는 모드 전환 확률로, 모드 i 에서 모드 j 로 전환할 가능성을 나타낸다. IMM 필터의 초기 입력값은 다음과 같다.

$$\begin{aligned} \hat{X}_{k-1|k-1}^{0j} &= \sum_{i=1}^r \hat{X}_{k-1|k-1}^i \mu_{i|j,k-1|k-1}, j = 1, \dots, r \\ P_{k-1|k-1}^{0j} &= \sum_{i=1}^r \mu_{i|j,k-1|k-1} \\ &\quad \times \left\{ P_{k-1|k-1}^i + \left[\hat{X}_{k-1|k-1}^i - \hat{X}_{k-1|k-1}^{0j} \right] \right. \\ &\quad \left. \times \left[\hat{X}_{k-1|k-1}^i - \hat{X}_{k-1|k-1}^{0j} \right]^T \right\}, j = 1, \dots, r \end{aligned} \quad (15)$$

본 IMM 프레임워크에서는 극좌표계 (polar coordinates)로 정의된 두 가지 동적 모델을 사용한다. 하나는 일정 속도 (Constant Velocity model with Polar velocity, CVP) 모델이며 다른 하나는 일정한 선회운동을 하는 (nearly Coordinated Turn model with Polar velocity, CTP) 모델[26]이다. 이에 대응하는 상태 벡터는 다음과 같이 정의된다.

$$X = [x \ y \ v \ \theta \ \omega]^T \quad (16)$$

여기서 x, y 는 차량의 중심 위치 좌표, v 는 극좌표계에서의 속도, θ 는 진행 방향 각도, ω 는 각속도를 나타낸다. CVP 모델에서 상

태는 일정 속도와 방향을 유지하면서 속도 기반의 위치 업데이트를 수행하는 이산 시간 상태방정식에 따라 전개된다.

$$X_{k+1} = \begin{bmatrix} x + vT\cos(\theta) \\ y + vT\sin(\theta) \\ v \\ \theta \\ 0 \end{bmatrix}_k + w_{v,k} \quad (17)$$

이때 프로세스 잡음 (process noise) $w_{v,k}$ 는 평균이 0인 가우시안 분포로 가정되며, 공분산 행렬 (covariance matrix)은 속도의 불확실성을 반영하도록 설정된다.

$$Q_{v,k} = \text{diag} \left[\begin{bmatrix} \sigma_{vx}^2 & 0 \\ 0 & \sigma_{vy}^2 \end{bmatrix}, T^2 \sigma_a^2, \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix} \right] \quad (18)$$

CTP 모델은 짧은 시간 동안 선속도와 각속도를 유지하며 차량이 곡선 경로를 따르는 회전 동역학을 반영한다. 이에 따른 이산 시간 상태방정식은 원호 경로를 따라 움직이는 움직임을 나타낸다.

$$X_{k+1} = \begin{bmatrix} x + \frac{2v}{\omega} \left\{ \sin\left(\frac{\omega T}{2}\right) \cos\left(\theta + \frac{\omega T}{2}\right) \right\} \\ y + \frac{2v}{\omega} \left\{ \sin\left(\frac{\omega T}{2}\right) \sin\left(\theta + \frac{\omega T}{2}\right) \right\} \\ v \\ \theta + \omega T \\ \omega \end{bmatrix}_k + w_{t,k} \quad (19)$$

이때 프로세스 잡음 $w_{t,k}$ 또한 평균이 0인 가우시안 분포로 모델링되며, 공분산 행렬은 회전과 가속에 따른 불확실성을 포함한다.

$$Q_{v,k} = \text{diag} \left[\begin{bmatrix} \sigma_{vx}^2 & 0 \\ 0 & \sigma_{vy}^2 \end{bmatrix}, T^2 \sigma_a^2, \begin{bmatrix} T^2 \sigma_a^2 / 3 & T^2 \sigma_a^2 / 2 \\ T^2 \sigma_a^2 / 2 & T^2 \sigma_a^2 \end{bmatrix} \right] \quad (20)$$

위에서 제시한 두 상태 모델은 비선형적 특성을 가지므로 IMM 프레임워크에서는 이를 선형화한 (linearized) 모델을 사용한다.

선형 칼만 필터를 적용하기 위해 업데이트 방정식은 행렬 형태로 표현되어야 한다.

$$X_{k+1} = \Phi X_k \quad (21)$$

상태 전이 행렬 (state transition matrix) Φ 는 상태 전이 방정식의 편미분을 이용하여 다음과 같이 근사화할 수 있다.

$$\Phi = \begin{bmatrix} \frac{\partial x}{\partial x} & \frac{\partial x}{\partial y} & \frac{\partial x}{\partial v} & \frac{\partial x}{\partial \theta} & \frac{\partial x}{\partial \omega} \\ \frac{\partial y}{\partial x} & \frac{\partial y}{\partial y} & \frac{\partial y}{\partial v} & \frac{\partial y}{\partial \theta} & \frac{\partial y}{\partial \omega} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ \frac{\partial \omega}{\partial x} & \frac{\partial \omega}{\partial y} & \frac{\partial \omega}{\partial v} & \frac{\partial \omega}{\partial \theta} & \frac{\partial \omega}{\partial \omega} \end{bmatrix} \quad (22)$$

CVP 모델의 경우 식 (17)을 선형화하여 상태 전이 행렬을 나타내면 다음과 같다.

$$X_{k+1} = \begin{bmatrix} 1 & 0 & T \cos(\theta) - v T \sin(\theta) & 0 \\ 0 & 1 & T \sin(\theta) & v T \cos(\theta) \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix} X_k \quad (23)$$

CTP 모델의 경우 식 (19)을 선형화하여 상태 전이 행렬을 나타내면 다음과 같다.

$$X_{k+1} = \begin{bmatrix} 1 & 0 & f_{11} & f_{12} & f_{13} \\ 0 & 1 & f_{21} & f_{22} & f_{23} \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & T \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix} X_k$$

$$\begin{aligned} f_{11} &= \frac{2}{\omega} \left\{ \sin\left(\frac{\omega T}{2}\right) \cos\left(\theta + \frac{\omega T}{2}\right) \right\} \\ f_{12} &= \frac{-2v}{\omega} \left\{ \sin\left(\frac{\omega T}{2}\right) \sin\left(\theta + \frac{\omega T}{2}\right) \right\} \\ f_{13} &= \frac{vT}{\omega} \{ \cos(\theta + \omega T) \} - \frac{v}{\omega^2} \{ \sin(\theta + \omega T) - \sin\theta \} \\ f_{21} &= \frac{2}{\omega} \left\{ \sin\left(\frac{\omega T}{2}\right) \sin\left(\theta + \frac{\omega T}{2}\right) \right\} \\ f_{22} &= \frac{2v}{\omega} \left\{ \sin\left(\frac{\omega T}{2}\right) \cos\left(\theta + \frac{\omega T}{2}\right) \right\} \\ f_{23} &= \frac{vT}{\omega} \{ \sin(\theta + \omega T) \} - \frac{v}{\omega^2} \{ \cos\theta - \cos(\theta + \omega T) \} \end{aligned} \quad (24)$$

Interaction step 이후, IMM 필터는 각 모드에 대해 EKF (extended Kalman filter)를 수행하여 상태를 추정하게 된다. 각 필터가 상호작용 단계에서 얻은 혼합 초기 조건을 사용하여 수행된다. 이 단계에서는 먼저 각 모드별 관측모델을 이용하여 추정값 $\hat{z}_k^j$ 을 산출하고, 칼만 이득을 통해 필터의 상태 추정값을 업데이트한다. 이 과정은 크게 예측 (prediction) 단계와 측정 업데이트 (measurement update) 단계로 구분된다.

첫 번째, 예측 단계에서는 이전 타임스텝의 혼합된 상태 추정값 $\hat{X}_{k-1|k-1}^{0j}$ 과 공분산 $P_{k-1|k-1}^{0j}$ 을 사용하여, 상태 전이 함수 $f^j(\cdot)$ 와 행렬 A_k^j 을 통해 현재 타임스텝의 상태 $\hat{X}_{k|k-1}^j$ 와 공분산 $P_{k|k-1}^j$ 를 예측한다.

$$\begin{aligned}\hat{X}_{k|k-1}^j &= f^j(\hat{X}_{k-1|k-1}^j) \\ P_{k|k-1}^j &= A_k^j P_{k-1|k-1}^{0j} (A_k^j)^T + Q_k^j\end{aligned}\quad (25)$$

두 번째, 측정 업데이트 단계 (measurement update)에서는 예측된 상태를 실제 관측값으로 보정하여 정확한 상태로 추정한다. 차량의 중심 좌표를 직접적으로 측정하는 것이 현실적으로 어렵기 때문에 본 연구에서는 차량의 우측 전방 좌표를 비선형 관측 모델 $h(x)$ 을 통해 차량의 중심으로 변환한다. 차량 중심 좌표를 사용하면 차량의 위치, 속도, 방향과 같은 상태를 더욱 정확하게 추정할 수 있다. 이를 통해 직접적인 차량 중심 좌표 측정 없이도 차량 중심의 위치, 속도, 방향을 정확하게 추정할 수 있다.

$$h(x) = \begin{bmatrix} x_c + r \cos(\alpha - \theta) \\ y_c + r \sin(\alpha - \theta) \end{bmatrix} = \begin{bmatrix} x_p \\ y_p \end{bmatrix} \quad (26)$$

여기서,

$$r = \sqrt{\left(\frac{L_w}{2}\right)^2 + \left(\frac{L_l}{2}\right)^2}, \quad \alpha = \tan^{-1}\left(\frac{L_w}{L_l}\right) \quad (27)$$

여기서 L_w 과 L_l 은 각각 차량의 전체 너비와 길이를 나타낸다. 또한 r 는 차량 중심에서 전방 우측 코너까지의 유클리드 거리이며 α 는 차량 중심 기준으로 전방 우측 코너가 형성하는 상대적인 각도를 의미한다, θ 는 차량의 진행 방향 각도 (heading angle)를 나타낸다.

IMM 필터링 과정에서 차량 상태 벡터는 차량의 기하학적 중심 좌표 (x_c, y_c) 을 기준으로 정의된다. 그러나 실제 센서 측정값 $z = (x_p, y_p)$ 는 보통 차량 전방 우측 코너와 가까운 지점에서 최적의

센서 융합 방법을 통해 획득된다. 상태 추정값과 측정값 간의 기준 좌표계를 일치시켜 일관성을 유지하기 위해서는, 예측된 상태 벡터를 측정 위치의 좌표계로 변환하는 과정이 필요하다. 이는 비선형 관측모델 $h(x)$ 을 통해 차량 중심 좌표를 실제 측정 좌표로 변환하여 수행된다. 이러한 변환을 통해, 실제 측정값과 추정값의 차이인 $z_k - \hat{z}_k^j$ (여기서 $\hat{z}_k^j = h(\hat{x}_k^j)$)을 얻을 수 있다. 이 값은 실제 센서의 측정값과 상태 예측값 간의 오차를 나타내며, 상태 추정값을 더 정확하게 갱신하는 데 중요한 역할을 한다.

이때, 칼만 이득 (L_k^j)을 정확히 계산하기 위해서는 측정 모델의 비선형성을 고려해야 한다. 즉, 상태 예측값을 실제 센서의 측정 위치로 변환하는 비선형 관측 모델 $h(x)$ 을 선형화하여 얻어진 자코비안 (Jacobian) 행렬이 필요하다. 이러한 선형화 과정에서 나오는 자코비안 행렬 H 는 다음과 같이 표현할 수 있다.

$$H = \begin{bmatrix} 1 & 0 & 0 & r \sin(a - \theta) & 0 \\ 0 & 1 & 0 & r \cos(a - \theta) & 0 \end{bmatrix} \quad (28)$$

이로부터 측정 모델과 이에 대응되는 잡음 공분산 행렬 R 은 아래와 같은 형태로 나타낼 수 있다.

$$Y_k = \begin{bmatrix} 1 & 0 & 0 & r \sin(a - \theta) & 0 \\ 0 & 1 & 0 & r \cos(a - \theta) & 0 \end{bmatrix} X_k + n_k$$

$$R = \begin{bmatrix} \sigma_x^2 & 0 \\ 0 & \sigma_y^2 \end{bmatrix} \quad (29)$$

이러한 모델 구성은 예측된 차량 중심 좌표의 상태 값을 실제 측정 위치인 센서 좌표로 명확하게 대응시키며, 칼만 필터의 업데이트 과정에서 일관성을 보장한다.

칼만게인 L_k^j 은 위에서 얻은 자코비안 행렬 H_k^j 을 이용해 아래와 같이

계산한다.

$$L_k^j = P_{k|k-1}^j H_k^{jT} (H_k^j P_{k|k-1}^j H_k^j + R_k^j)^{-1} \quad (30)$$

마지막으로, 각 모드의 상태 추정값 추정은 이러한 좌표계 변환 과정을 통해 얻은 추정값 $\hat{z}_k^j$ 과 실제 측정값 z_k 의 차이를 기반으로 현재상태 $\hat{X}_{k|k}^j$ 를 추정함으로써 이뤄진다. 공분산 $P_{k|k}^j$ 도 다음의 수식을 이용하여 수행된다.

$$\begin{aligned} \hat{X}_{k|k}^j &= \hat{X}_{k|k-1}^j + L_k^j (z_k - \hat{z}_k^j) \\ P_{k|k}^j &= (I - L_k^j H_k^j) P_{k|k-1}^j \end{aligned} \quad (31)$$

여기서 $\hat{X}_{k|k}^j$ 는 모드 j 의 갱신된 상태 추정값, $\hat{X}_{k|k-1}^j$ 는 모드 j 의 사전 예측 상태 추정값이며, 이전 시점 $k-1$ 까지 정보를 바탕으로 현재 시점 k 의 상태를 예측한 값이다.

또한 이 단계에서 각 모드의 가능성 (mode likelihood)과 업데이트된 모드 확률 (mode probability update)을 다음과 같이 계산한다.

$$\begin{aligned} A_{j,k} &= N(z_k - \hat{z}_k^j, S_k^j), \quad j = 1, \dots, r \\ \mu_{j,k} &= \frac{A_{j,k} \sum_{i=1}^r p_{ij} \mu_{i,k-1}}{\sum_{i=1}^r A_{j,k} \sum_{i=1}^r p_{ij} \mu_{i,k-1}}, \quad j = 1, \dots, r \end{aligned} \quad (32)$$

여기서 S_k^j 는 모드 j 에 대응하는 측정값의 공분산이다. 마지막으로 결합 (combination) 단계에서는 모드 확률을 가중치로 사용하여 각 모드의 상태 추정값을 결합함으로써 최종 상태 추정값을 산출한다. 최종 공분산은 각 모드의 공분산을 모드 확률로 가중

평균한 후, 전체 평균 상태 추정값과 개별 모드 상태 추정값 사이의 편차를 반영하는 보정항을 추가하여 계산한다. 수식적으로 최종 상태 추정값 $\hat{X}_{k|k}$ 과 공분산 $P_{k|k}$ 은 다음과 같이 표현할 수 있다.

$$\begin{aligned}\hat{X}_{k|k} &= \sum_{j=1}^r \hat{X}_{k|k}^j \mu_{j,k} \\ P_{k|k} &= \sum_{j=1}^r \mu_{j,k} \left\{ P_{k|k}^j + [\hat{X}_{k|k}^j - \hat{X}_{k|k}] \times [\hat{X}_{k|k}^j - \hat{X}_{k|k}]^T \right\}\end{aligned}\quad (33)$$

[27] 에서 제시된 바와 같이, IMM 프레임워크는 모드 특화된 모델들과 확률적 혼합 (probabilistic mixing)을 통해 차량의 향후 움직임을 예측할 수 있게 한다. 상태 추정 단계 이후에는 다음 반복을 위한 혼합된 초기 상태를 계산하는 확률적 혼합 절차가 수행된다. 이후 각 모드는 혼합된 초기 상태를 이용하여 고유의 모션 모델로 다음 상태를 예측한다.

$$\hat{X}_{k+1|k}^j = f^j(\hat{X}_{k|k}^{0j}), \quad j = 1, \dots, r \quad (34)$$

여기서 $\hat{X}_{k|k}^{0j}$ 는 모드 j 에 대한 혼합 초기 상태이며, $f^j(\cdot)$ 는 모드 j 에 대응하는 상태 전이 함수 (state transition function)를 의미한다. 최종 예측 상태는 모드별 예측값들을 각 모드의 확률로 가중 평균하여 구한다.

$$\hat{X}_{k+1|k} = \sum_{j=1}^r \hat{X}_{k+1|k}^j \mu_{j,k} \quad (35)$$

그러나 $\hat{X}_{k+1|k}$ 는 차량 중심 좌표 기준으로 표현되어 있기에, 실제 측정 가능한 우측 전방 코너 좌표로의 변환을 $h(x)$ 을 통해 수행하여 최종 상태 $\hat{Y}_{k+1|k}^j$ 를 도출한다.

$$\hat{Y}_{k+1|k}^j = h(\hat{X}_{k+1|k}^j) \quad (36)$$

이러한 일련의 과정으로 IMM 필터는 비선형적이고 동적인 차량의 움직임 상황에서도 낮은 불확실성을 유지하며, 센서 융합 전략과 결합하여 더욱 신뢰할 수 있는 차량 상태 추정 결과를 제공한다.

제 4 장 결 과

제 4 장에서는 차량 추적 성능 평가를 위한 시뮬레이션 환경과 실험 결과를 제시하였다. 세부적으로 4.1절에서는 라이다 탐지 포인트 구성, 동적 바운딩 박스 생성 방법 및 pure pursuit 기반 차량 운동을 기반으로 구축한 시뮬레이션 환경에 관해 설명하였다. 4.2절에서는 단일 및 다중 차량 추적 시나리오에서 제안된 DRL(Deep Reinforcement-Learning) 기반 센서 융합 기법과 IMM 필터의 성능에 대해 시뮬레이션을 통해 분석하고 평가하였다. 4.3절에서는 마할라노비스 거리 기반 방법과 DRL 방법 간의 성능 비교 분석을 수행하여 DRL 기법의 우수한 적응성과 강건성을 입증하였다. 마지막으로, 4.4절에서는 저비용의 라이다와 카메라를 활용한 도로변 센서 시스템을 구성하였다. 4.5절에서는 이를 실제 교차로 환경에 적용한 현장 실험 결과를 통해 제안된 방법의 현장 실용성과 신뢰성을 검증하였다.

4.1 시뮬레이션 환경 구성

4.1.1 라이다 탐지 포인트 구성

차량과 라이다 센서 간의 거리 추정을 위해 차량을 직사각형으로 모델링하고, 라이다 빔이 차량 표면과 교차하는 지점을 계산하였다. 차량의 진행 방향각도 (heading angle)을 사용하여 차

량의 전방, 후방 및 측면 모서리에 대한 기울기를 센서 좌표계 기준으로 도출하였다. 라이다 센서의 빔과 차량 모서리 (전방, 후방, 측면) 간 교차점은 다음 행렬 방정식을 이용하여 계산된다.

$$\begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} -v_{slope} & 1 \\ -b_{slope} & 1 \end{bmatrix}^{-1} \begin{bmatrix} C_v \\ C_b \end{bmatrix} \quad (37)$$

이때, v_{slope} 는 차량 모서리의 기울기를, b_{slope} 는 라이다 빔의 기울기를 나타낸다. C_v 와 C_b 는 각각 차량 모서리와 라이다 빔의 y 절편이며, x, y 는 교차점의 좌표를 의미한다. 이를 통해 차량 각면 (전방, 후방, 측면)의 연장선과 라이다 빔이 교차하는 후보지점을 계산할 수 있으며, 이 중 실제 차량 표면 위에 존재하는 교차점만을 유효한 탐지점으로 채택하였다. 만약 다수의 유효한 교차점이 발견될 경우, 센서와 가장 가까운 교차점을 최종 라이다 탐지점으로 선정하였다 (Fig. 5 참조).




Fig. 5 라이다 탐지점 분류

추가적으로, 라이다의 반사 신호 강도는 입사각이 증가할수록 확산 반사 (diffuse reflection)로 인해 감소하기 때문에, 시뮬레이션에서는 각도에 따른 반사 강도의 제약 조건을 포함하였다. 이를 통해 라이다 센서의 현실적인 특성을 시뮬레이션에 반영하였다. 본 연구에서 사용한 라이다 센서의 각도 해상도는 1° 이며, 최대 측정 가능한 입사각은 70° 로 설정하여 실제 실험에서 사용된 센서의 사양과 일치시켰다.

4.1.2 바운딩 박스 생성

컴퓨터 비전 분야에서 객체의 위치 파악 및 분류를 위해 널리 사용되는 바운딩 박스를 센서와 차량의 모서리 간의 기하학적 관

계를 이용하여 시뮬레이션상에서 생성하고자 하였다. 본 연구에서는 센서에서 차량의 네 개 모서리까지의 방위각을 계산하고, 이 중 최소 및 최대값을 기준으로 바운딩 박스의 좌측 및 우측 경계를 정의하였다. 이 방법을 통해 센서에 대한 차량의 방향과 위치 변화에 따라 동적으로 바운딩 박스를 생성할 수 있다. 이는 YOLO와 같은 카메라 기반 객체 탐지 알고리즘이 2차원 이미지 공간에서 객체의 범위를 해석하는 방식을 반영한 것이다.

4.1.3 차량 운동 및 제어 시뮬레이션

실제 교통 시나리오를 묘사하기 위해, 시뮬레이션 내 차량의 움직임은 차량의 위치, 속도, 가속도뿐만 아니라 회전 동작이 시작되고 끝나는 지점 등 다양한 무작위 조건들에 따라 결정된다. 이러한 무작위 파라미터들은 직진 주행과 교차로에서의 좌회전과 같은 다양한 경로를 생성한다. 차량 제어는 경로 추적 기법인 Pure Pursuit 알고리즘[28]을 이용하여 구현된다. 이 알고리즘은 차량의 뒷바퀴 축을 기준으로 설정한 차량 위치 (x_v, y_v) 에서 look ahead distance l_d 을 초과하는 최초의 궤적상의 점을 목표점 (x_{goal}, y_{goal}) 으로 설정한다. 목표점은 다음과 같은 수식으로 정의된다.

$$(x_{goal}, y_{goal}) = (x_{t,i}, y_{t,i}), \quad i = \min \{k \mid d_k > l_d\} \quad (38)$$

여기서, 차량 위치와 기준 경로상의 k 번째 점 $(x_{t,k}, y_{t,k})$ 사이의 거리 d_k 는 다음과 같다.

$$d_k = \sqrt{(x_{t,k} - x_v)^2 + (y_{t,k} - y_v)^2} \quad (39)$$

차량의 현재 진행 방향 각도를 θ_v , 목표점과 차량 위치를 연결하는 직선이 이루는 각도를 θ_g 라고 하면, 두 각도의 차이 γ 는 다음과 같다.

$$\gamma = \theta_g - \theta_v = \tan^{-1} \left(\frac{y_{goal} - y_v}{x_{goal} - x_v} \right) - \theta_v \quad (40)$$

이 각도 차이 γ 를 기반으로 필요한 곡률 κ 는 다음 수식으로 계산된다.

$$\kappa = \frac{2 \sin(\gamma)}{l_d} \quad (41)$$

이렇게 구한 곡률 κ 과 차량의 앞뒤 차축 간 거리 L 을 이용해 차량의 필요한 조향각 δ 를 다음과 같이 계산한다.

$$\delta = \tan^{-1}(L \cdot \kappa) \quad (42)$$

최종적으로 계산된 조향각 δ 를 기반으로 차량의 핸들을 조정하여 차량이 설정된 경로를 따라 정밀하게 추종할 수 있다.

직진과 회전과 같은 다양한 주행 형태를 모두 포함함으로써, 본 시뮬레이션 환경은 차량과 센서 (라이다 및 카메라) 간의 복잡한 상호작용을 효과적으로 모델링하였다. 이러한 구성은 제안된 센서 융합 프레임워크가 다양한 움직임 상황에서 얼마나 정확하고 유연하게 작동하는지 평가하기 위한 강건한 시뮬레이션 플랫폼을 제공한다. Fig. 6는 차량과 라이다 빔 교차점, 카메라 방위각을 통해 얻은 바운딩 박스 추정 결과를 포함하는 시뮬레이션 결과를 보여준다. 이러한 시뮬레이션 환경의 구축을 통해 실제 교차로 환경과 유사한 다양한 시나리오를 효과적으로 재현하고, 이를 바탕으로 강화학습 모델을 훈련시킬 수 있었다.





Fig. 6 차량-센서 시뮬레이션 결과


4.2 단일/다중 차량 추적 시뮬레이션 결과

이전에 설명한 시뮬레이션 시나리오를 이용하여, 제안된 알고리즘의 성능을 단일 차량 추적 환경에서 평가하였다. 평가 대상 궤적은 좌회전 주행 (Fig. 7)과 직진 주행 (Fig. 8)이다.




(a)

IMM-based vehicle trajectory estimation



(b)

Estimated mode probability



(c)






Fig. 7 단일 차량 좌회전 시뮬레이션 결과: (a) 제안된 DRL 기반 센서 융합을 이용한 차량 코너 위치 결과, (b) 제안된 IMM 기반 차량 중심 궤적 추정 결과, (c) 제안된 IMM 기반 모드 확률, (d) 제안된 IMM 기반 속도 및 방향 추정 결과

DRL-based sensor fusion




(a)



IMM-based vehicle trajectory estimation



(b)




(c)



(d)


Fig. 8 단일 차량 직진 시뮬레이션 결과: (a) 제안된 DRL 기반 센서 융합을 이용한 차량 코너 위치 결과, (b) 제안된 IMM 기반 차량 중심 궤적 추정 결과 (c) 제안된 IMM 기반 모드 확률, (d) 제안된 IMM 기반 속도 및 방향 추정 결과

다중 차량 환경 (Fig. 9)에서는 두 대의 차량이 동시에 이동하며, 한 차량은 좌회전 주행을 수행하고 다른 차량은 교차로를 직진으로 통과하였다. 동일한 센서 융합 및 추적 프레임워크를 각 차량에 독립적으로 적용하여 알고리즘을 평가하였다.




(a)

IMM-based vehicle trajectory estimation




(b)

1st Vehicle estimated mode probability



2nd Vehicle estimated mode probability



(c)




Fig. 9 다중 차량 시나리오 (1번 차량: 좌회전, 2번 차량: 직진)의 시뮬레이션
 결과: (a) DRL 기반 센서 융합을 이용한 차량 코너 위치 결과, (b) 제안된
 IMM 기반 차량 중심 궤적 추정 결과, (c) 제안된 IMM 기반 각 차량의 모
 드 확률 결과,(d) 제안된 IMM 기반 속도 및 방향 추정 결과

Table 1은 제안된 방법의 시뮬레이션 성능을 단일 및 다중 차량 추적 시나리오에 걸쳐 요약하여 나타낸 것이다. 성능 평가는 차량 상태의 추정값과 실제값 간의 차이를 기반으로 계산된 제공된 평균 제공 오차 (RMSE)를 활용하였다. 여기서 평가된 차량 상태는 차량 중심 위치, 속도, 그리고 진행 방향 각도를 포함한다.

Table 1 시뮬레이션 환경에서 제안된 방법의 성능 평가

시나리오 유형	주행 형태	위치 RMSE	속도 RMSE	헤딩각 RMSE
단일 차량	좌회전	0.066 <i>m</i>	0.491 <i>m/s</i>	0.038 °
	직진	0.012 <i>m</i>	0.419 <i>m/s</i>	0.001 °
다중 차량	좌회전	0.054 <i>m</i>	0.468 <i>m/s</i>	0.041 °
	직진	0.015 <i>m</i>	0.444 <i>m/s</i>	0.002 °

제안된 방법은 다양한 차량 기동과 추적 시나리오 전반에 걸쳐 일관되고 정확한 상태 추정을 제공하는 것으로 나타났다. 특히, 직진 주행 시나리오의 위치 RMSE 값은 좌회전 주행 시나리오 대비 위치 RMSE가 약 0.05*m* 낮게 나타났으며, 이는 직진 주行的 상대적으로 간단한 차량 운동 특성 때문으로 분석된다.

4.3 마할라노비스 거리 기반 방법과 심층

강화학습 방법의 비교 분석

제안된 방법의 효과성을 평가하기 위해, 마할라노비스 거리 기반 방법과 제안된 심층 강화학습 기반 방법 (DRL)의 성능을 세 가지 대표적인 시나리오를 통해 비교 분석하였다.

타원 (Mahalanobis ellipse)는 예측 공분산에서 도출된 신뢰 구역을 나타내며, 마할라노비스 거리 임계값을 기반으로, 통계적으로 허용할 수 있는 영역을 정의한다. 마할라노비스 거리는 다음과 같이 표현된다.

$$D_M^2 = (x - \mu)^T S^{-1} (x - \mu) \leq G \quad (43)$$

여기서 x 는 후보 행동, S 는 공분산 행렬, G 는 미리 정의된 마할라노비스 거리 임계값이다 (이차원 공간에서 95% 신뢰 수준일 때 일반적으로 $G \approx 5.991$). 측정값의 마할라노비스 거리가 임계값 G 보다 작으면 측정값이 예측 범위 내에서 있다고 본다. 마할라노비스 기반 방법은 모든 행동 후보에 대해 마할라노비스 거리를 계산하고 거리가 가장 작은 점을 마할라노비스 거리 기반 방법의 행동으로 선택하도록 했다. 세 가지 시나리오는 다음 Fig. 10에 나타내었다.

첫 번째 시나리오 (a)에서는 IMM 필터로 예측된 지점이 신뢰 타원 내에 위치하여 마할라노비스 거리 기반 방법의 행동 후보군에 포함되었으며, 마할라노비스 거리 기반 방법은 이 지점을 행동으로 선택하였다. 동일한 행동 후보군을 사용한 DRL 방법은 차량의 실제 전방 우측 코너 포인트에 더 가까운 지점을 선택하여 더 높

은 정확성을 나타냈다.

두 번째 시나리오 (b)에서도 IMM 필터로 예측된 지점이 신뢰 타원 내에 위치하여 마할라노비스 거리 기반 방법의 후보군에 포함되었으나, 센서 융합으로부터 도출된 다른 지점들은 타원 내에 위치하지 않아 마할라노비스 거리 기반 방법은 예측된 지점을 선택하였다. 반면 DRL 방법은 차량의 실제 우측 코너에 가장 가까운 지점을 선택하여 더 정확한 결정을 선택하였다.

세 번째 시나리오 (c)에서는 IMM 필터로 예측된 지점이 신뢰 타원 외부에 위치하여 마할라노비스 거리 기반 방법 방법의 후보군에서 제외되었다. 마할라노비스 거리 기반 방법은 후보군 내에서 예측된 지점과 가장 가까운 지점을 선택했지만, DRL 방법은 실제 차량 위치에 가장 가까운 지점을 선택하였다.

이러한 비교는 고정된 통계적 신뢰 영역에만 의존하여 상황에 대한 적응력이 부족한 마할라노비스 거리 기반 마할라노비스 거리 기반 방법의 한계를 명확히 보여준다. 반면, DRL 방법은 예측의 불확실성과 기하학적 근접성을 모두 고려하여 상황에 유연하게 대응하였다.






Fig. 10 시나리오별 마할라노비스 거리 기반 방법과 제안 알고리즘의 행동 선택 비교 결과

또한 갑작스러운 가속과 감속 시나리오를 구성하여 시뮬레이션에서 수행하였다. Fig. 11의 빨강색 동그라미는 급격한 속도 변화가 생긴 구간이다. 급격한 속도 변화가 포함된 시나리오에서 DRL 방법은 실제 차량 궤적을 밀접하게 추적하며, 실제값과 일치하는 행동을 적응적으로 선택하였다. 이는 갑작스러운 가속 또는 감속과 같은 동적 조건에서도 DRL 방법이 높은 강건성을 보인다는 것을 보여준다. 반면 마할라노비스 거리 기반 방법은 갑작스러운 동적 조건에서 예측 상태에 크게 의존하여 부정확한 행동을 선택하였다. 이에 따라 예측된 상태와 실제 상태 간의 편차가 커지고 예측 정확도가 떨어져 추적 오류를 유발하였다.



(a)



(b)

Fig. 11 차량의 급가속-감속 시나리오 결과: (a) 마할라노비스 거리 기반 방법과 제안한 방법(DRL) 간의 행동 선택 방법 비교, (b) 제안된 IMM 기반 차량 속도 및 방향 추정 결과

또한, step 1, 2 그리고 3으로 구성된, 차량이 완전히 가려졌다가 다시 나타나는 시나리오 (Fig. 12)를 구성하여 시뮬레이션을 수행하였다. Step 1은 목표 차량이 부분적으로 가려진 상태, step 2는 목표 차량이 완전히 가려진 상태, 그리고 step 3는 목표 차량이 다시 탐지되는 상태를 나타내며, 이 단계들은 순차적으로 진행된다.






Fig. 12 차량간 가림 현상 시나리오

Fig. 13의 빨간색 동그라미는 차량 간 가림 현상이 발생한 구간을 나타낸다. DRL 방법은 최신 관측 데이터를 바탕으로 적절한 행동을 지속적으로 선택하여 가림 현상으로부터 효과적으로 회복하였다. 이에 반해 마할라노비스 거리 기반 방법은 이전 예측 결과에 과도하게 의존하여 적응성이 부족하여 가림 현상으로부터 효과적으로 회복하지 못하였다. 반면 마할라노비스 거리 기반 방법은 이전 예측 결과에 지나치게 의존하여 적응성이 떨어졌고, 가림 현상으로부터 효과적으로 회복하지 못하였다.



(a)



(b)

Fig. 13 차량간 가림 현상 시나리오 결과: (a) 마할라노비스 거리 기반 방법과 제안한 방법 (DRL) 간의 행동 선택 방법 비교 (b) 제안된 IMM기반 차량 속도 및 방향 추정 결과

이 결과는 DRL 방법이 동적 변화나 가림 현상과 같은 불확실성이 높은 환경에서도 최신 관측 데이터를 활용해 신속하고 정확하게 회복하며, 통계적 신뢰 영역에만 의존하는 마할라노비스 거리 기반 방법보다 월등히 높은 적응성과 강건성을 가진다는 것을 보여준다.

4.4 센서 시스템

도로변에서 데이터를 획득하기 위해 삼각대 기반의 센서 플랫폼을 개발하였다. 해당 플랫폼에는 저비용의 2D 라이다와 단안 카메라가 통합되었으며, 구성된 센서 시스템의 구조를 Fig. 14에 나타내었다. 본 시스템은 도심의 교차로 환경에 설치되었으며, 센서 높이는 차량의 평균 범퍼 높이 (약 0.5-0.6 m)에 맞추어 보정하였다. 통합된 센서의 세부적인 사양은 Table 2에 정리하였다.



Fig. 14 삼각대 기반 2D 라이다 및 단안 카메라 센서 플랫폼

Table 2 현장 실험에 사용된 센서의 세부 사양

센서 종류	항목	값
2D 라이다 (Slamtec Mapper M2M2)	거리 측정 범위	40m
	정확도	0.02m
	측정 주파수	10hz
	각도 해상도	1°
	가격	700,000₩
단안 카메라 (AF500QHD webcam)	시야각	78°
	프레임 속도	30fps
	가격	34,310₩
RTK-GPS (C099-F9P-01, Ublox)	업데이트 주기	8hz
	위치정확도	0.01m+1ppm

4.5 단일/다중 차량 추적 현장 실험 결과

현장 실험은 서울특별시 강서구 마곡동에 위치한 4방향 교차로에서 수행되었다. 데이터 수집을 위해 활용된 실험 현장을 Fig. 15에 나타내었다. 실제 차량의 기준 위치 (ground truth)를 얻기 위하여 RTK-GPS 시스템을 사용하였으며, GPS 안테나는 차량 루프 중앙에 설치되었다 (Fig. 16 참조).




Fig. 15 서울시 강서구 마곡동 현장 실험 대상지 모습




Fig. 16 차량 루프 중앙에 설치된 GPS 안테나

수집된 GPS 데이터는 라이다 좌표계로 변환하였다. 라이다 센서는 센서 위치를 기준으로 상대적인 거리만을 측정하기 때문에, GPS에서 얻어진 위치 데이터를 라이다 기준 좌표계에 맞추기 위하여 회전 행렬을 사용하여 변환하였다. 이때 센서의 위치가 좌표계의 원점이 되도록 설정하였다.

현장 실험에서는 단일 차량 추적 시나리오로 좌회전 주행과 직진 주행 상황을 고려하였으며, 다중 차량 추적 시나리오로는 선행 차량이 좌회전을 수행한 후, 뒤따르는 차량이 동일하게 좌회전을 수행하는 상황을 다루었다. 삼각대 기반 센서 플랫폼을 활용하여 촬영한 현장 실험 이미지는 Fig. 17에 나타내었으며, 이에 대응되는 라이다 포인트 데이터 플롯을 Fig. 18에 제시하였다.



Fig. 17 삼각대 기반 센서 플랫폼을 이용하여 촬영한 현장 실험 이미지







Fig. 18 현장 실험 이미지에 대응되는 라이다 포인트 데이터

단일 차량 좌회전 시나리오 (Fig. 19)에서는 차량의 추정된 궤적이 실제 차량의 중심 위치 (ground truth)와 매우 밀접하게 일치하여 우수한 추적 성능을 나타냈다. 좌회전 과정 중 모드 확률 분석 결과, 초기 과도 상태 이후에는 대부분 CTP 모델이 지배적인 것으로 나타나, 이 모델이 차량의 전형적인 회전 기동을 효과적으로 반영하고 있음을 알 수 있었다. 또한 속도 추정치는 실제 측정된 속도를 일관되게 따라가며, 방향 각도의 추정 역시 차량의 실제 방향 변화를 정확히 반영하였다.





(b)



(c)






Fig. 19 단일 차량 좌회전 현장 실험 결과: (a) 제안된 DRL 기반 센서 융합을 이용한 차량 코너 위치 결과, (b) 제안된 IMM 기반 차량 중심 궤적 추정 결과 (c) 제안된 IMM 기반 모드 확률 (d) 제안된 IMM 기반 속도 및 방향 추정 결과

직진 주행 시나리오 (Fig. 20)에서도 제안된 추적 방법은 위치 추정에서 다시 한번 정확성을 나타냈다. 그러나 모드 확률 분석에서 직진 궤적임에도 불구하고 지속적으로 CTP 모델이 지배적인 것으로 나타났다. 이는 단안 카메라 센서의 고정된 방향과 제한된 시야각으로 인해, 직진 주행 경로조차 센서의 시점에서 약간 대각선 방향으로 관측되었기 때문이다. 따라서 실제로는 일관된 방향 각도를 유지하며 직진하는 차량이 라이다 센서 관점에서


는 경로가 대각선으로 인지되어, IMM 필터가 이를 회전 동작으로 해석하게 되었다. 이러한 해석에도 불구하고 Fig. 20 (d)에서 나타난 결과는 속도 및 방향 각도의 추정에서 일관성과 정확성을 유지하고 있음을 보여준다. 구체적으로, 차량의 추정된 속도는 실제 측정된 속도의 전반적인 경향을 잘 따라가며 미세한 편차에도 불구하고 속도 변화를 효과적으로 포착하였다. 또한 방향 각도의 추정치도 전반적인 추이를 적절히 나타내며 안정적인 추적 성능을 보였다.




(a)



(b)




(c)






(d)

Fig. 20 단일 차량 직진 현장 실험 결과: (a) 제안된 DRL 기반 센서 융합을 이용한 차량 코너 위치 결과, (b) 제안된 IMM 기반 차량 중심 궤적 추정 결과 (c) 제안된 IMM 기반 모드 확률, (d) 제안된 IMM 기반 속도 및 방향 추정 결과

다중 차량 시나리오 (Fig. 21)에서는 두 대의 차량이 순차적으로 좌회전을 수행하였으며, 후행 차량이 선행 차량 (목표 차량)이 회전을 거의 완료할 무렵 그 뒤를 따랐다. 제안된 알고리즘은 목표 차량 궤적을 정확히 추정하였으며 (Fig 21 (b)), 모드 확률 분석 결과 역시 CTP 모델이 각 차량의 회전 동작을 정확히 반영하며 지배적으로 나타났다. 또한 속도와 방향 각도의 추정치 역시 실제 측정된 데이터와 밀접하게 일치하여 전체적인 경향을 효과적으로 포착하였다.



(a)






Fig. 21 다중 차량 시나리오 (1번 차량 (목표 차량) : 좌회전, 2번 차량: 좌회전)의 현장 실험 결과: (a) 제안된 IMM 기반 차량 중심 궤적 추정 결과, (b) 1번 차량 (목표 차량) IMM 기반 차량 중심 궤적 추정 결과, (c) 제안된 IMM 기반 각 차량의 모드 확률 결과, (d) 제안된 IMM 기반 속도 및 방향 추정 결과

Table 3 는 단일 및 다중 차량 시나리오에서 현장 실험을 통한 제안된 방법의 성능을 요약하여 나타낸 것이다.

Table 3 현장 실험 환경에서 제안된 방법의 성능 평가

시나리오 유형	주행 형태	위치 RMSE	속도 RMSE	헤딩각 RMSE
단일 차량	좌회전	0.092m	0.224m/s	3.507 °
	직진	0.078m	0.401m/s	2.554 °
다중 차량	좌회전 (목표 차량)	0.147m	0.397m/s	3.074 °

성능 평가를 위해 차량 중심 위치, 속도, 방향 각도의 추정 값과 실제 값 간의 차이를 기반으로 제공된 평균 제공 오차 (RMSE)를 계산하였다. 현장 실험에서는 시뮬레이션과 달리 오직 목표 차량만이 GPS를 장착하여 실제 기준 위치를 측정하였기 때문에, 다중 차량 시나리오의 RMSE 값은 목표 차량에만 적용되었다. 위치 RMSE는 모든 시나리오에서 0.147m 이하로 우수한 위치 추정 성능을 확인했다. 또한 직접 구축한 시뮬레이션 환경에서 학습한 강화학습 모델을 현장 실험에도 성공적으로 적용하였다.

제 5 장 결 론

본 연구는 저비용의 2D 라이다와 단안 카메라를 융합한 센서 기술을 활용하여 복잡한 교차로 환경에 최적화된 강건하고 경제적인 차량 추적 시스템을 제안하였다. 차량 위치 및 상태 추정의 정확성을 크게 향상시켰으며, 특히 IMM 필터는 CVP와 CTP 모델을 활용하여 센서 노이즈, 차량간 가림 현상, 복잡한 차량 기동 상황에서도 일관된 성능을 유지하였다. 또한, 심층 강화학습을 기반으로 실시간 센서 융합 방법 개발되었다.

시뮬레이션 결과, 제안된 프레임워크는 단일 및 다중 차량 시나리오 전반에 걸쳐 일관되게 낮은 RMSE 값을 나타내며 정확성을 입증하였다. 구축한 시뮬레이션 환경에서 학습된 강화학습 모델은 실제 교차로에서 수행된 현장 실험에서도 높은 성능을 보였다. 이를 통해 제안된 시스템의 높은 신뢰성과 예산 제약이 있는 도시 환경을 포함한 다양한 도심 상황에서의 넓은 적용 가능성을 입증하였다.

종합적으로, 본 연구에서 제안된 차량 추적 프레임워크는 교차로 환경에서의 차량 운동 추정을 YOLO, RANSAC 및 IMM 예측의 성공적인 통합을 통해 실현하였으며, 심층 강화학습 기반의 실시간 센서 융합 전략 개발을 통해 실제 도심 환경에서도 그 우수성을 입증하였다. 이는 향후 지능형 교통 시스템의 발전과 도시 환경 내 안전성과 교통 효율성 향상을 위한 중요한 기술적 기반을 제공한다.

향후 연구는 Decision Transformer 기반의 강화학습 알고리즘

을 탐구하여 시스템 성능을 더욱 최적화하는 방향으로 진행될 예정이다. 또한, 보행자의 행동을 정확하게 추정하고 예측할 수 있도록 이러한 알고리즘의 확장을 통해 차량 이동과 함께 보행자의 움직임을 통합적으로 관리할 수 있는 지능형 교통 시스템의 종합적 성능 향상을 목표로 하고 있다.

참 고 문 헌

- [1] Datondji, S. R. E., Dupuis, Y., Subirats, P., & Vasseur, P. (2016). A survey of vision-based traffic monitoring of road intersections. *IEEE Transactions on Intelligent Transportation Systems*, 17(10), 2681-2698.
- [2] National Highway Traffic Safety Administration. (2024). Traffic safety facts 2022: A compilation of motor vehicle traffic crash data (Tech. Rep.). Washington, DC: U.S. Department of Transportation.
- [3] U.S. Department of Transportation. (n.d.). Intersection safety. Federal Highway Administration. Retrieved from <https://highways.dot.gov/safety/intersection-safety/about>
- [4] Korea Road Traffic Authority. (2024). Traffic accident statistics analysis 2024 (2023 Data). Wonju, South Korea: Korea Road Traffic Authority.
- [5] Yao, Z., Shen, L., Liu, R., Jiang, Y., & Yang, X. (2019). A dynamic predictive traffic signal control framework in a

cross-sectional vehicle infrastructure integration environment. IEEE Transactions on Intelligent Transportation Systems, 21(4), 1455-1466.

- [6] Wu, Y. J., Lian, F. L., & Chang, T. H. (2006). Traffic monitoring and vehicle tracking using roadside cameras. In Proceedings of the IEEE International Conference on Systems, Man, and Cybernetics, 6, 4631-4636.
- [7] Cui, Y., Xu, H., Wu, J., Sun, Y., & Zhao, J. (2019). Automatic vehicle tracking with roadside LiDAR data for the connected-vehicles system. IEEE Intelligent Systems, 34(3), 44-51.
- [8] Lin, C., Wang, Y., Gong, B., & Liu, H. (2023). Vehicle detection and tracking using low-channel roadside LiDAR. Measurement, 218, 113159.
- [9] Zhang, J., Xiao, W., Coifman, B., & Mills, J. P. (2020). Vehicle tracking and speed estimation from roadside LiDAR. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 13, 5597-5608.
- [10] Zhao, J., Xu, H., Liu, H., Wu, J., Zheng, Y., & Wu, D. (2019). Detection and tracking of pedestrians and vehicles using

roadside LiDAR sensors. *Transportation Research Part C: Emerging Technologies*, 100, 68-87.

- [11] Messelodi, S., Modena, C. M., & Zanin, M. (2005). A computer vision system for the detection and classification of vehicles at urban road intersections. *Pattern Analysis and Applications*, 8, 17-31.

- [12] Fleck, T., Ochs, S., Zofka, M. R., & Zollner, J. M. (2020). Robust tracking of reference trajectories for autonomous driving in intelligent roadside infrastructure. In *Proceedings of the IEEE Intelligent Vehicles Symposium (IV)* (pp. 1337-1342).

- [13] Lashkov, I., Yuan, R., & Zhang, G. (2023). Edge-computing-empowered vehicle tracking and speed estimation against strong image vibrations using surveillance monocular camera. *IEEE Transactions on Intelligent Transportation Systems*. Advance online publication.

- [14] Xiao, Y., Peng, Z., Chen, L., Deng, Y., Li, Z., & Lei, X. (2022, November). Combining monocular camera and 2D LiDAR for target tracking using deep convolution neural network based detection and tracking algorithm. In *2022 International Conference on Frontiers of Communications, Information System and Data Science (CISDS)* (pp. 122-127). IEEE.

- [15] Hocaoglu, G. S., & Benli, E. (2025). Multiple objects localization with camera-LiDAR sensor fusion. *IEEE Sensors Journal*, 25(7), 11892-11905.
- [16] Simon, M., Amende, K., Kraus, A., Honer, J., Samann, T., Kaulbersch, H., & Michael Gross, H. (2019). Complexer-yolo: Real-time 3d object detection and tracking on semantic point clouds. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition workshops*
- [17] Yuan, Y., & Liu, Y. (2024). BEVEFNet: A Multiple Object Tracking Model Based on LiDAR-Camera Fusion. *Procedia Computer Science*, 242, 560-567.
- [18] Huang, K., & Hao, Q. (2021). Joint multi-object detection and tracking with camera-LiDAR fusion for autonomous driving. In *Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)* (pp. 6983-6989).
- [19] Fu, Z., Shang, H., Song, L., Li, Z., & Chen, C. (2022). Camera-LiDAR fusion-based three-stage data association framework for 3D multi-object tracking. In *Proceedings of the IEEE International Conference on Networking, Sensing and Artificial Intelligence (NSAI)* (pp. 152-157).

- [20] Yin, H., Lu, Y., Lin, J., Schratter, M., & Watzenig, D. (2023). Multi-object tracking with object candidate fusion for camera and LiDAR data. In Proceedings of the IEEE International Conference on Intelligent Transportation Systems (ITSC) (pp. 2965-2970).
- [21] Wang, X., Fu, C., Li, Z., Lai, Y., & He, J. (2022). DeepfusionMOT: A 3D multi-object tracking framework based on camera-LiDAR fusion with deep association. IEEE Robotics and Automation Letters, 7(3), 8260-8267.
- [22] Gupta, A., Jain, S., Choudhary, P., & Parida, M. (2024). Dynamic object detection using sparse LiDAR data for autonomous machine driving and road safety applications. Expert Systems with Applications, 255, 124636.
- [23] Sualeh, M., & Kim, G. W. (2020). Visual-LiDAR based 3D object detection and tracking for embedded systems. IEEE Access, 8, 156285-156298.
- [24] Ester, M., Kriegel, H.-P., Sander, J., & Xu, X. (1996, August). A density-based algorithm for discovering clusters in large spatial databases with noise. In Proceedings of the 2nd International Conference on Knowledge Discovery and Data Mining (KDD) (pp. 49-60).

- [25] Bar-Shalom, Y., Li, X. R., & Kirubarajan, T. (2004). Estimation with applications to tracking and navigation: Theory algorithms and software. Hoboken, NJ: Wiley.

- [26] Li, X. R., & Jilkov, V. P. (2003). Survey of maneuvering target tracking. Part I: Dynamic models. IEEE Transactions on Aerospace and Electronic Systems, 39(4), 1333-1364.

- [27] Jeon, W., & Rajamani, R. (2017). Rear vehicle tracking on a bicycle using active sensor orientation control. IEEE Transactions on Intelligent Transportation Systems, 19(8), 2638-2649.

- [28] Coulter, R. C. (1992). Implementation of the pure pursuit path tracking algorithm (Tech. Rep.). Pittsburgh, PA: Carnegie Mellon University.

부 록

1) DQN 하이퍼 파라미터

Table 4 DQN 하이퍼 파라미터

하이퍼 파라미터	계수
배치크기	64
리플레이 메모리 버퍼 사이즈	100000
학습률	0.0005
할인률	0.6
타겟 네트워크 업데이트 주기	25
최대 에피소드 수	50000
최적화 알고리즘	Adam
ϵ 감쇠율	0.95

2) DQN 신경망 구조

Table 5 DQN 신경망 구조

층	뉴런수	활성화함수
입력층	10	-
은닉층 1	256	tanh
은닉층 2	256	tanh
은닉층 3	256	tanh
출력층	256	linear

3) IMM 파라미터

본 연구에서는 센서 융합 전략에 따라 IMM 필터 내 칼만 필터 모델의 관측 잡음 공분산 (R) 및 프로세스 잡음 공분산 (Q) 을 다음과 같이 조정하였다. 센서 융합 방식별 신뢰도 차이를 다르게 주기 위해 DQN이 선택하는 각 행동에 따라 R 을 다르게 설정하였다. 또한 시뮬레이션과 현장 실험 간의 센서 특성 차이를 고

려하여, 두 경우에 대해 서로 다른 Q, R 행렬값을 적용하였다.

- 시뮬레이션

Table 6 시뮬레이션 환경에서의 공분산 행렬 R 설정값

행동	융합 방법	Model 1: CVP	Model 2: CTP
1	RANSAC 교차점	$\begin{bmatrix} 0.035 & 0 \\ 0 & 0.01 \end{bmatrix}$	$\begin{bmatrix} 0.01 & 0 \\ 0 & 0.01 \end{bmatrix}$
2	YOLO 최대 방위각과 RANSAC 선 모델의 교차점	$\begin{bmatrix} 0.1 & 0 \\ 0 & 0.01 \end{bmatrix}$	$\begin{bmatrix} 0.01 & 0 \\ 0 & 0.01 \end{bmatrix}$
3	YOLO 최소 방위각과 RANSAC 선 모델의 교차점	$\begin{bmatrix} 0.01 & 0 \\ 0 & 0.05 \end{bmatrix}$	$\begin{bmatrix} 0.035 & 0 \\ 0 & 0.05 \end{bmatrix}$
4	횡 방향 가장 가까운 점	$\begin{bmatrix} 0.1 & 0 \\ 0 & 0.1 \end{bmatrix}$	$\begin{bmatrix} 0.1 & 0 \\ 0 & 0.1 \end{bmatrix}$
5	IMM 예측 점	$\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$	$\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$

Table 7 시뮬레이션 환경에서의 공분산 행렬 Q 설정값

Model 1: CVP	$\begin{bmatrix} 0.01 & 0 & 0 & 0 & 0 \\ 0 & 0.01 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}$
Model 2: CTP	$\begin{bmatrix} 0.1 & 0 & 0 & 0 & 0 \\ 0 & 0.015 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0.1 & 0.1 \\ 0 & 0 & 0 & 0.1 & 0.1 \end{bmatrix}$

- 현장 실험

Table 8 현장 실험 환경에서의 공분산 행렬 R 설정값

행동	융합 방법	Model 1: CVP	Model 2: CTP
1	RANSAC 교차점	$\begin{bmatrix} 0.01 & 0 \\ 0 & 0.01 \end{bmatrix}$	$\begin{bmatrix} 0.01 & 0 \\ 0 & 0.001 \end{bmatrix}$
2	YOLO 최대 방위각과 RANSAC 선 모델의 교차점	$\begin{bmatrix} 0.1 & 0 \\ 0 & 0.1 \end{bmatrix}$	$\begin{bmatrix} 0.1 & 0 \\ 0 & 0.01 \end{bmatrix}$
3	YOLO 최소 방위각과 RANSAC 선 모델의 교차점	$\begin{bmatrix} 0.1 & 0 \\ 0 & 0.1 \end{bmatrix}$	$\begin{bmatrix} 0.1 & 0 \\ 0 & 0.01 \end{bmatrix}$
4	횡 방향 가장 가까운 점	$\begin{bmatrix} 0.01 & 0 \\ 0 & 0.01 \end{bmatrix}$	$\begin{bmatrix} 0.01 & 0 \\ 0 & 0.01 \end{bmatrix}$
5	IMM 예측 점	$\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$	$\begin{bmatrix} 0.1 & 0 \\ 0 & 1 \end{bmatrix}$

Table 9 현장 실험 환경에서의 공분산 행렬 Q 설정값

Model 1: CVP	$\begin{bmatrix} 0.1 & 0 & 0 & 0 & 0 \\ 0 & 0.1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}$
Model 2: CTP	$\begin{bmatrix} 0.1 & 0 & 0 & 0 & 0 \\ 0 & 0.1 & 0 & 0 & 0 \\ 0 & 0 & 1.5 & 0 & 0 \\ 0 & 0 & 0 & 0.1 & 0.1 \\ 0 & 0 & 0 & 0.1 & 0.1 \end{bmatrix}$

4) RANSAC 파라미터

RANSAC 알고리즘의 수행을 위해 다음과 같은 파라미터를 설정하였다.

- Threshold: 0.3
- 최대 반복 횟수(Max Iteration): 100회

교차로 도로변 센서 시스템을 위한 강화학습 기반의 단안 카메라와 2D 라이다 센서 융합 알고리즘

곽 민 재

전자전기공학과 전자전기공학전공

중앙대학교 대학원

교차로는 차량의 다양한 방향에서 합류와 분기가 동시에 일어나 복잡한 교통 환경을 형성하며, 이에 따라 단일 도로에 비해 사고 위험이 현저히 높다. 실제로 2022년 미국 도로교통안전국 (NHTSA)의 보고서에 따르면 전체 차량 사고의 49%가 교차로에서 발생했으며, 우리나라에서도 2023년 기준 전체 교통사고 중 교차로 사고 비율이 48.3%로 단일 도로 (43.6%)보다 높았다. 이에 교차로에서의 정밀한 차량 추적 시스템은 모니터링하는 것을 넘어, 충돌 위험을 예방하고 향후에는 교통 흐름의 최적화로 확장될 수 있다.

본 연구에서는 저비용의 2D 라이다와 단안 카메라를 융합한 도로변 센서 시스템을 구축하여 교차로 환경에서 차량의 위치와 상태를 정확히 추정하는 방법을 제안하였다. YOLO, RANSAC, IMM 필터 기반 예측을 결합하여 차량 위치 추정의 정확도를 높였으며, 다양한 센서 데이터를 실시간으로 최적의 방식으로 결합하기 위해 심층 강화학습 (DQN) 기반의 적응형 센서 융합 전략을 개발하였다.

제안된 방법은 MATLAB 기반의 시뮬레이션과 실제 교차로 현장 실험을 통해 검증되었으며, 차량의 위치, 속도, 방향 추정에서 우수한 성능을 보였다. 특히, 다양한 주행 시나리오에서 제안된 DQN 기반 센서 융합 전략은 기존의 마할라노비스 거리 기반 접근법보다 정확도 측면에서 우수함을 입증하였다. IMM 필터는 CVP 모델과 CTP 모델을 융합하여 센서 잡음과 차량의 급격한 움직임, 부분적인 탐지 실패 상황에서도 안정적인 상태 추정을 가능케 했다.

결론적으로, 본 연구에서 제안한 저비용 차량 추적 시스템은 복잡한 교차로 환경에서도 정확하고 견고한 차량 모니터링을 통해 교통안전 및 효율성을 크게 개선할 수 있는 실용적이고 경제적인 해결 방안을 제공한다. 향후 연구로는 Decision Transformer 기반으로 성능을 더욱 최적화하고, 보행자 행동 예측까지 확장하여 종합적인 지능형 교통 시스템으로 발전시킬 계획이다.

핵심어 : 센서 융합, 교차로 차량 추적, 심층 강화학습, 2D 라이다,
단안 카메라, 지능형 교통 시스템

ABSTRACT

Reinforcement Learning-Based Sensor Fusion of Monocular Camera with 2D LiDAR for Roadside Sensor System at a Intersection

Kwak Minjae

Major in Electrical and Electronic Engineering
Dept. of Electrical and Electronic Engineering
The Graduate School of Chung-Ang University

Intersections constitute complex traffic environments due to simultaneous merging and diverging vehicle paths from various directions, resulting in significantly higher accident risks compared to single-road segments. According to the National Highway Traffic Safety Administration (NHTSA), intersections accounted for 49% of all vehicle accidents in the United States in 2022. Similarly, intersection-related accidents represented 48.3% of total traffic incidents in South Korea in 2023, surpassing those on single-road segments (43.6%). Consequently, precise vehicle tracking systems at intersections can extend beyond mere vehicle monitoring, proactively mitigating collision risks, and potentially evolving toward the optimization of overall traffic flow management.

This study proposes a low-cost roadside sensor system integrating 2D LiDAR and monocular cameras to accurately estimate vehicle positions and states within intersection environments. By combining YOLO-based object detection, RANSAC line fitting, and IMM filter-based motion prediction, the proposed system significantly enhances the accuracy of vehicle localization. Furthermore, an adaptive sensor fusion strategy leveraging deep reinforcement learning (DQN) was developed to optimally combine diverse sensor data in real-time.

The proposed approach was validated through MATLAB-based simulations and real-world intersection field tests, demonstrating superior performance in estimating vehicle position, velocity, and orientation. Specifically, the DQN-based sensor fusion strategy exhibited markedly greater accuracy and robustness compared to conventional Mahalanobis distance-based approaches across various driving scenarios. Additionally, the IMM filter, integrating Constant Velocity Polar (CVP) and nearly Coordinated Turn Polar (CTP) models, ensured robust state estimation despite sensor noise, abrupt vehicle maneuvers, and partial detection failures.

In conclusion, the proposed low cost vehicle tracking system offers a practical and cost-effective solution for improving traffic safety and efficiency through precise and robust vehicle monitoring in complex intersection environments. Future research will further optimize system performance with Decision Transformer, and expand the framework to include pedestrian behavior prediction,

thereby advancing toward comprehensive intelligent transportation systems.

Keywords : Sensor Fusion, Intersection Vehicle Tracking, Deep Reinforcement Learning, 2D LiDAR, Monocular Camera, Intelligent Transportation Systems

감사의 글

중앙대학교 전자전기공학과에서 석사과정을 시작한 지 어느덧 2년이 흘렀습니다. 모빌리티 및 제어 연구실에서 학부 연구생으로 시작한 지는 벌써 3년이 되어갑니다. 연구를 진행하며 여러 어려움이 있었지만, 주변 사람들의 응원과 지지 덕분에 무사히 마칠 수 있었습니다.

처음 연구실 문을 열고 들어섰던 순간을 아직도 선명히 기억합니다. 책상이나 서랍 하나 없는 텅 빈 공간이었지만, 교수님께서 직접 청소해 주신 연구실을 보며 열심히 해야겠다고 다짐했던 때가 마치 어제 같습니다. 지난 3년 동안 좋은 주제로 연구하며 학문적으로나 개인적으로나 많은 성장을 이룰 수 있었습니다.

본 논문을 작성하는 동안 따뜻한 격려와 세심한 지도로 항상 큰 힘이 되어 주신 지도교수 전용선 교수님께 진심으로 감사드립니다. 교수님의 깊은 통찰과 아낌없는 지도가 있었기에 방향을 잃지 않고 연구를 완성할 수 있었습니다.

연구실 생활 동안 연구에 대한 고민을 제 일처럼 같이 해준 의준이 형과 원석이에게 감사합니다. 연구에 관한 이야기도 많이 하고 열심히 하는 두 명에게 많은 자극을 받아 더욱 책임감 있게 연구에 임할 수 있었습니다. 항상 웃음이 끊이질 않게 해줘서 재밌게 연구실 생활할 수 있었던 것 같습니다. 항상 감사하게 생각합니다.

바쁜 와중에도, 휴일일 때도 한 번의 불평 없이 여러 번 실험을 도와준 동현이에게 고맙다는 말을 전하고 싶습니다. 동현이가

없었다면 연구 과정 중 실험에서 많은 어려움을 겪었을 것입니다.

힘들고 지칠 때마다 늘 곁에서 함께 고민하고 해결책을 찾아 주며, 연구 외적으로도 큰 도움을 준 채승이에게 특별히 감사의 마음을 전합니다. 채승이의 따뜻한 말들과 진심 어린 조언 덕분에 힘든 순간을 잘 견딜 수 있었고, 대학원 생활을 더 의미 있고 즐겁게 만들어 주었습니다. 대학원 생활을 견뎌낼 수 있었던 가장 큰 힘이었습니다.

마지막으로 언제나 나의 든든한 버팀목이 되어 주고, 힘들 때마다 위로해 주며, 편안히 쉴 수 있는 안식처가 되어 준 사랑하는 우리 엄마, 아빠, 그리고 누나에게 깊은 사랑과 감사를 전합니다. 가족의 따뜻한 응원과 사랑이 없었다면 긴 대학원 생활을 끝까지 해내기 어려웠을 것입니다. 앞으로 더 큰 사랑으로 보답할 수 있도록 열심히 노력하며 살아가겠습니다.

2025년 8월

곽민재 올림

