

지식재산 교육과 연구 (한국지식재산교육연구학회 논문지)
제10권 제2호 (2022년 12월)
pp.027 - 036

오렌지 파이 하드웨어와 AI를 활용한 RGB 색상분류 모델 개발 및 성능분석

Development and performance analysis of
RGB Color classification model using Orange Pi hardware and AI

김벼리¹, 궤민재², 추현규³, 이수민⁴, 위재빈⁵, 김나현⁶, 전주현⁷

¹중앙대학교 융합공학부, ²중앙대학교 도시시스템공학과,

³중앙대학교 기계공학부, ⁴중앙대학교 전자전기공학부,

⁵중앙대학교 경영학부, ⁶중앙대학교 국제물류학과,

⁷중앙대학교 다빈치교양대학 교수

Byeori Kim¹, Minjae Kwak², Hyungyu Choo³, Sumin Lee⁴, Jaebin Wee⁵, Nahyun Kim⁶,

Jui-hyun Jeon⁷

¹Dept. of Integrative Engineering, Chung-Ang University,

²Dept. of Urban Engineering, Chung-Ang University,

³Dept. of Mechanical Engineering, Chung-Ang University,

⁴Dept. of Electrical and Electronics Engineering, Chung-Ang University,

⁵Dept. of Business Administration, Chung-Ang University,

⁶Dept. of International Logistics, Chung-Ang University,

⁷Da Vinci College of General Education / Professor, Chung-Ang University

Received October 31, 2022; Reviewed December 22, 2022; Accepted December 29, 2022

Online Published December 028, 2022

Corresponding Author: jhjeon@cau.ac.kr (Jui-hyun Jeon)

(요약)

본 연구에서는 주변 조명에 따라 카메라에 다르게 포착되는 R, G, B 색상을 머신러닝 및 딥러닝 라이브러리를 활용하여 분류하는 모델을 개발하고, 이를 이용해서 오렌지 파이를 통해 수집한 데이터를 분류해보는 실험을 진행하였다. 결정 트리, 랜덤 포레스트를 이용하여 분류 모델을 구현하였고, CNN 알고리즘을 활용하여 모델을 개발하여 총 3개의 모델을 완성했다. 성능 테스트 결과 각각 ROC_AUC score 99.6%, 98.6%, 99.9%의 결과를 얻었다. 이외 Accuracy, Precision, Recall, F1 score도 종합적으로 고려하였을 때, CNN algorithm, 결정 트리, 랜덤 포레스트 순으로 좋은 성능을 나타냄을 확인하였다. 추가로 가성비가 좋은 오렌지 파이를 통해 수집한 사진으로 만든 모델을 사용하여 분류하는 실험을 성공적으로 수행함으로써 적은 비용의 기기로도 충분히 AI 관련 프로젝트를 진행할 수 있음을 보였다.

(주제어)

오렌지 파이, 인공지능, 머신러닝, 딥러닝, 자율주행, 사회문제 해결, 색상 분류, RGB

(Abstract)

In this study, we have developed three models to classify R, G, B colors that are captured differently by the camera depending on the surrounding lighting using machine learning and deep learning libraries, and conducted an experiment to classify data collected by Orange Pi. Three Classification models were implemented using a decision Tree, random forest, and CNN algorithm. As a result of performance evaluation using ROC_AUC score, values of 99.6%, 98.6%, 99.9% were derived respectively. Also, when considering Accuracy, Precision, Recall, and F1 score comprehensively, it was confirmed that they showed better performance in the order of CNN algorithm, decision tree, and Random Forest. In addition, by successfully conducting experiments on classification using photo data collected through cost-effective Orange Pi, we have shown that AI-related projects can be carried out sufficiently with low-cost devices.

(Keyword)

Orange Pi, artificial intelligence, machine learning, deep learning, autonomous driving, solving social problems, color classification, RGB

곽민재 (Minjae Kwak)

2017년 3월 - 현재 중앙대학교 전자전기공학부 / 도시시스템공학과 학사과정
<관심분야> 자율주행, 제어, Lidar

김나현 (Nahyun Kim)

2021년 3월 - 현재 중앙대학교 국제물류학과 학사과정
<관심분야> 물류자동화, 자율주행, IOT, 빅데이터

김버리 (Byeori Kim)

2019년 3월 - 현재 중앙대학교 융합공학부 / 소프트웨어학부 학사과정
<관심분야> 나노소재, 반도체, AI, 로봇틱스, 자율주행

위재빈 (Jaebin Wee)

2021년 3월 - 현재 중앙대학교 경영학부 학사과정
<관심분야> 경영, 제4차 산업혁명, 자율주행

이수민 (Sumin Lee)

2020년 3월 - 현재 중앙대학교 전자전기공학부 학사과정
<관심분야> 반도체, 회로, 제어, 자율주행

추현규 (Hyungyu Choo)

2019년 3월 - 현재 중앙대학교 기계공학부 학사과정
<관심분야> 모빌리티, 자율주행, 로봇틱스

1. 서론

2. 이론적 배경

- 2.1 지도 학습(Supervised learning)
- 2.2 결정 트리와 분류 알고리즘(Classification Algorithm)
- 2.3 랜덤 포레스트 분류기(Random Forest Classifier)
- 2.4 딥러닝과 딥러닝 프레임워크
- 2.5 합성곱 신경망(CNN)
- 2.6 오렌지 파이(Orange Pi)

3. 실험

- 3.1 머신러닝, 딥러닝을 활용한 색상(RGB) 분류 모델 제작 및 성능 평가
- 3.2 오렌지 파이 자율주행 및 제어 실험
- 3.3 오렌지 파이 카메라로 촬영한 데이터로 R, G, B 색상 분류 실험

4. 실험 결과

- 4.1 결정 트리/랜덤 포레스트/합성곱 신경망 기반 분류 모델 성능 측정 결과 및 분석
- 4.2 결정 트리/랜덤 포레스트/합성곱 신경망 기반 모델 오렌지 파이 수집 데이터 분류 결과 및 분석

5. 결론

참고문헌 (References)

1. 서론

사람의 눈으로는 빨간색(R), 초록색(G), 파란색(B) 구분이 쉽지만, 컴퓨터의 경우 이미지의 RGB 값을 3차원 배열 형식으로 인식하기 때문에 이 값들의 명확한 경계 결정에 어려움이 존재한다. 예를 들어, 빨간색의 경우 이상적으로는 (R, G, B) 값이 (255, 0, 0)이지만, (165, 56, 79), (147, 38, 61)과 같이 이상적인 값을 가지지 않는 경우에도 사람은 이를 빨간색으로 인식한다. 그리고 조도에 따라 실제 색상과 다르게 인식하는 상황도 존재한다. 이러한 이유로 햇빛과 조명의 명도와 각도 등 다양한 환경에서 색상 분류의 필요성이 제기된다. 이와 같은 문제를 해결하기 위해 농산물의 신선도 예측 [1], 패션 이미지 분류 [2] 등 RGB 데이터를 이용한 방법이 연구되었지만, 어두운 환경에서의 색상 분류와 경제적 비용의 측면에서 현재 진행된 연구들이 완전하다고 볼 수 없다고 판단되었다.

이에 본 연구에서는 색상의 유·무광, 대상의 각도, 조명의 명도 등의 종속변인 하에 머신러닝, 딥러닝을 이용하여 다양한 환경에서 여러 각도로 촬영한 사진에 대한 색상 분류를 수행하였다. 이 과정에서 라즈베리파이(Raspberry Pi)보다 상용화 정도는 낮지만, 상대적으로 적은 비용이라는 가격적 측면과 카메라로 촬영한 이미지의 AI 모델 분류와 같은 다양한 기능적 측면의 장점들을 고려하여 본 실험에서는 ‘오렌지 파이(Orange Pi)’를 사용하였다. 그리고 해당 연구를 통해 물류, 교육, 경제, 인권 등 다양한 분야에서 발생할 수 있는 사회적 문제에 대한 제언 및 해결 방향을 제시하고자 한다. 또한, RGB 분류모델을 개발함으로써 신지식재산권을 확보하고자 한다.

2. 이론적 배경

2.1 지도 학습(Supervised learning)

지도 학습은 머신러닝 알고리즘 중 하나로 데이터에 대한 특징(feature)과 라벨(label) 즉, 특정 그룹에 대한 명시적인 정답이 주어진 데이터를 가지고 학습(learning)을 진행하여 새로운 데이터로부터 특정 값을 예측하기 위한 모델을 생성하는 방법이다. [3]

2.2 결정 트리과 분류 알고리즘(Classification Algorithm)

결정 트리(Decision Tree)는 의사결정 규칙을 도표화하여 관심 대상이 되는 집단을 몇 개의 소집단으로 분류하거나 예측을 수행하는 분석 방법이다. [4] 따라서 결정 트리는 데이터베이스로부터 데이터를 탐사, 미지의 패턴들을 찾아내기 위한 데이터 마이닝은 물론, 텍스트 발굴, 정보 발췌(Information Extraction), 머신러닝 그리고 패턴인식과 같은 다양한 분야에서 가장 효과적인 도구들로서 인식되고 있다. [5]

2.3 랜덤 포레스트 분류기(Random Forest Classifier)

랜덤 포레스트 분류기는 입력 벡터와 독립적으로 샘플링된 랜덤 벡터를 사용하여 각 분류기가 생성되는 트리 분류기의 조합으로 구성되며, 각 트리는 입력 벡터를 분류하기 위해 가장 인기 있는 클래스에 대해 단위 투표를 실시한다. [5] Scikit-learn 라이브러리에서 랜덤 포레스트 알고리즘을 제공한다. 또한, 데이터 전처리 단계, 데이터 재샘플링 기법, 평가 매개 변수 및 알고리즘의 성능을 조정/최적화하기 위한 검색 인터페이스와 같은 기계 학습 파이프라인에 필수적인 기타 보조 기능을 포함한다. [6]

2.4 딥러닝과 딥러닝 프레임워크

딥러닝은 머신러닝의 한 분야로서, 여러 비선형 변환기법들로 구성된 다중 처리 계층을 사용하여 높은 수준의 추상화, 즉 다량의 데이터나 복잡한 자료들 속에서 핵심적인 내용 또는 기능을 요약하는 작업을 하는 알고리즘의 집합이다. [7]

TensorFlow는 다양한 하드웨어 환경에서 인공지능망 모델을 쉽게 생성하고 학습할 수 있는 인터페이스를 제공한다. 이는 복잡하고 자세한 하드웨어 조작에서 벗어나 해결하고자 하는 문제에 최적화된 모델을 생성하는 데에만 집중할 수 있도록 연구자의 생산성을 향상시킨다. 한편, Keras는 Python으로 작성된 작고, 고도의

모듈화된 신경망 라이브러리이다. Keras는 TensorFlow 위에서 실행할 수 있다. [7]

2.5 합성곱 신경망(CNN)

합성곱 신경망(Convolutional Neural Network, CNN)은 최소한의 전처리를 사용하도록 설계된 다계층 퍼셉트론의 한 종류이다. [7] 이는 영상의 분류나 영상 속의 특정 객체를 검출하는 부분에서 우수한 성능을 보인다. 특히, CNN을 지원하는 프레임워크를 사용하면 좋은 결과를 얻을 수 있는데, TensorFlow 라이브러리에서 지원한다. [7]

2.6 오렌지 파이(Orange Pi)

오렌지 파이(Orange Pi)는 단일 보드 컴퓨터(Single-Board Computer)의 한 종류로, 오픈소스 하드웨어의 일종이다. 이는 낮은 비용과 다기능성이라는 장점을 가지고 있으며, 안드로이드, 리눅스 기반 시스템, 라즈베리 파이 등 다양한 운영체제를 구동할 수 있다.

3. 실험

3.1 머신러닝, 딥러닝을 활용한 색상(RGB) 분류 모델 제작 및 성능 평가

3.1.1 모델 구현 및 성능 평가

1. 데이터 수집

주변 조명에 따라 같은 색이더라도 카메라에 다르게 찍히고 빨간색, 초록색, 파란색의 범위도 다양하다. 이에 따라 여러 가지 종류의 빨간색, 초록색, 파란색의 색종이를 주변 환경과 빛을 다양하게 조절하여 데이터를 수집하였다. 총 12개의 색종이로 데이터를 수집하였다. 12개의 색종이는 다음과 같다.



[그림 1] 같은 조명, 빛이 있는 환경에서 촬영한 12개의 색종이 사진

[Figure 1] 12 colored paper pictures taken in the same lighting and light environment

주변이 밝을 때의 사진과 어두울 때의 사진은 같은 색종이여도 차이를 보인다. 각 빨간색, 초록색, 파란색이 카메라에 비치는 모습을 촬영하여 데이터를 수집했다. 아래 사진에서 같은 색종이라도 주변 환경, 빛의 차이에 따라 다르게 보인다는 것을 확인할 수 있다. 총 빨간색, 초록색, 파란색 각각 58개씩 조명에 따라 달라지는 빨간색, 초록색, 파란색 사진을 수집하였다.



[그림 2] 주변 조명, 빛에 따라 달라지는 색종이 사진 수집 결과

[Figure 2] Colored paper photo collection results that vary depending on the surrounding lighting and light

2. 데이터 전처리

이전에서 언급했듯이 빨간색, 초록색, 파란색 데이터를 각각 59개씩 수집하였다. 이들의 이미지 사이즈는 3024×3024 로 크기가 너무 큰 이미지를 학습시키기 어려운 컴퓨터 사양 환경을 고려하여, 256×256 사이즈로 분할하여 새 이미지들을 생성하였다. 이에 따라 각각 7018개의 빨간색, 초록색, 파란색 데이터, 총 21054개의 데이터를 생성하였다. 이후 훈련 데이터(train data), 시험 데이터(test data)로 약 9:1의 비율로 나누어서 RGB 각각 훈련 데이터 6316개, 시험 데이터 702개씩 만들어서 총 훈련 데이터셋은 18948개, 시험 데이터셋은 2106개로 확보했다. 이후 전처리 과정은 모델에 따라 차이가 있어서 이후 과정은 모델별로 분류하여서 정리했다.

① 결정 트리/랜덤 포레스트 분류기를 이용한 RGB 분류 모델을 구현하기 위한 데이터 전처리 과정

실제 오렌지 파이로 수집한 데이터에서 색을 인식한다고 할 때, 카메라에서 색상만 있는 부분을 촬영하기 보다는 다른 사물들, 여백 등이 섞여서 촬영되는 것이 현실적이므로 이를 고려하여 중간 부분만 크롭하는 형식으로 데이터를 처리하는 것으로 하였다. 모델에 사용되는 데이터는 최종적으로 $128 \times 128 \times 3$ 사이즈로 정리된 데이터를 기준으로 한다. 그러나 scikit-learn의 결정 트리/랜덤 포레스트 분류기의 경우 3차원의 이미지 데이터를 입력값으로 받지 않아서, R channel의 데이터 평균, G channel의 데이터 평균, B channel의 데이터 평균을 저장하는 형식으로 데이터를 가공하였다. 그리고 각 데이터의 label을 Red는 0, Green은 1, Blue는 2로 하여 label을 부여했다.

② 합성곱 신경망 분류기를 이용한 RGB 분류 모델을 구현하기 위한 데이터 전처리 과정

R, G, B 평균값의 데이터를 저장하기보다는 이미지 그 자체를 입력값으로 넣어서 예측하기 위해 딥러닝을 활용한 분류 모델을 추가로 만들었다. 이에 따라 Tensorflow, keras 라이브러리를 사용하여 합성곱 신경망 RGB 색상 분류 모델을 추가로 구현하였다. 여기서는 앞과 다르게 $128 \times 128 \times 3$ 의 컬러 이미지를 그대로 입력값으로 받아서 분류 결과를 볼 수 있다. 마찬가지로 Red는 0, Green은 1, Blue는 2로 label을 부여했다.

3. 모델 구현 및 모델 훈련

① 결정 트리/랜덤 포레스트 분류기를 이용한 RGB 분류 모델을 구현하기 위한 데이터 전처리 과정

결정 트리와 랜덤 포레스트 분류기의 경우 scikit-learn에 구현된 GridSearchCV를 사용하여 가장 좋은 결과가 나오는 하이퍼파라미터를 찾는다. 그리고 이 하이퍼파라미터를 사용하여 모델을 생성한다.

모델을 생성한 후 각 준비된 데이터(훈련 데이터, 훈련 데이터 레이블)를 바탕으로 모델을 훈련시킨다.

② 합성곱 신경망 분류기를 이용한 RGB 분류 모델을 구현하기 위한 데이터 전처리 과정

전형적인 CNN 구조를 이용하여 모델을 만든다. 특징 추출 부분으로는 convolutional layer와 maxpooling layer를 3번 반복하여 쌓아서 구성하였다. 이 때 사용하는 활성화 함수는 ReLU 함수이다. 이후 flatten 함수를 통해 fully connected layer를 구성하고 마지막에 softmax 활성화 함수를 이용해서 R, G, B 색상을 분류한다.

모델을 구성한 후 컴파일을 진행한다. 사용한 optimizer는 adam이고, loss는 categorical cross entropy를 기준으로 한다. 컴파일이 완료되면 과적합 방지를 위해 EarlyStopping을 이용하여 모델을 훈련시킨다. 결정 트리, 랜덤 포레스트 분류기와 마찬가지로 훈련 데이터, 훈련 데이터 레이블을 기준으로 훈련시킨다.


4. 훈련 데이터셋으로 성능 측정 및 평가

기존에 분류 모델을 훈련시키기 전, 데이터를 훈련 데이터와 시험 데이터로 분리했었다. 모델을 훈련시킬 때 훈련 데이터를 이용하여 모델을 훈련시켰는데, 모델을 평가할 때는 따로 분리했던 시험 데이터를 이용하여 모델 성능을 평가한다. 이렇게 하는 이유는 모델을 훈련시킬 때 사용하지 않은 데이터들을 사용하여 모델을 평가하면 편향을 제거한, 비교적 일반적인 정확도를 예측해 볼 수 있기 때문이다. 성능을 비교하기 위해 정확도(Accuracy), 정밀도(Precision), 재현율(Recall), F1 점수(F1 score), 분류기 성능 평가점수(ROC_AUC_score)를 측정한다.

3.2 오렌지 파이 자율주행 및 제어 실험

3.2.1 실험준비물

자율주행 차량 제원은 가로 18cm 세로 11cm 높이 12cm, 실험용 인식 박스는 12cm×12cm×12cm, 트랙 폭은 25cm로 구성했다. 카메라 해상도 320×240(OVGA) 이며, 자율주행 프로그램은 Armbian을 사용했다. 색종이는 무광3매(빨강, 초록, 파랑 각각 1매), 유광 3매(빨강, 초록, 파랑 각각 1매)를 사용했다.



[그림 3] 자율주행 차량 제원(좌), 실험용 인식 박스(우)

[Figure 3] Autonomous vehicle specifications(left), Experimental recognition box(right)

3.2.2 실험방법

1. 자율주행 차량 키트를 조립한다.
2. 자율주행 차량이 데이터를 수집할 수 있는 트랙을 만든다.
3. 그림과 같이 실험용 인식 박스에 색종이(무광 3매 - 빨강, 초록, 파랑 각각 1매, 유광 3매 - 빨강, 초록, 파랑 각각 1매, 총 6매)를 실험용 인식 박스에 붙인다.



[그림 4] 실험용 인식 박스에 색종이를 붙인 모습(좌), 자율주행 차량이 이미지를 촬영하는 모습(우)

[Figure 4] Color paper pasted on the lab recognition box(left), Autonomous vehicle taking images(우)

4. 트랙에서 카메라를 통해 수집한 데이터를 바탕으로 딥러닝으로 훈련한다.
5. 트랙의 임의의 위치에 실험용 인식 박스를 놓고, 자율주행 차량이 주행하면서, 차량에 있는 카메라 모듈이 차량 전방에 있는 이미지를 촬영한다.
6. 여러 가지 조건을 바꾸어 가며 실험을 계속 진행한다. (색깔 변화, 박스를 놓는 각도 변화(0°, 30°, 45°), 주변이 밝은 경우와 어두운 경우, 색종이의 무광과 유광 여부에 따른 차이로 4가지 조건을 설정했다.)

3.3 오렌지 파이 카메라로 촬영한 데이터로 R, G, B 색상 분류 실험


3.3.1 실험 방법

훈련 데이터셋으로 훈련시킨 3가지의 분류 모델(결정 트리, 랜덤 포레스트, 합성곱 신경망)과 3.2 실험에서 촬영한 사진을 바탕으로 실험을 진행하였다. 촬영된 이미지를 기존에 훈련시킨 모델에 입력값으로 넣어서 색종이의 색상(R, G, B)을 예측하게 하였고, 이 예측 결과를 통해 세 분류 모델의 공통점과 차이점에 대해 비교 분석을 진행하였다.

4. 실험 결과

4.1 결정 트리/랜덤 포레스트/합성곱 신경망 기반 분류 모델 성능 측정 결과 및 분석

훈련 데이터셋(test Dataset)을 바탕으로 분류한 결과를 나타낸 오차 행렬(Confusion Matrix)는 다음과 같다.



[그림 5] 각 분류기의 오차 행렬

[Figure 5] Confusion Matrix of each Classifier

랜덤 포레스트 분류 모델이 잘못 분류하는 데이터가 가장 많은 것을 알 수 있고, 합성곱 신경망 모델이 가장 잘 분류하는 것을 확인할 수 있다.

각 표로 모델별 정확도와 Red, Green, Blue 각 분류 결과에 따른 정밀도, 재현율, F1 점수를 표로 정리하였다.

[표 1] 결정 트리 분류기의 정확도, 정밀도, 재현율, F1 점수

[Table 1] Accuracy, Precision, Recall, F1 score of Decision Tree Classifier

Decision Tree	Red	Green	Blue
Accuracy	0.9948		
Precision	0.9986	0.9943	0.9915
Recall	0.9972	0.9915	0.9957
F1 score	0.9979	0.9929	0.9936

[표 2] 랜덤 포레스트 분류기의 정확도, 정밀도, 재현율, F1 점수

[Table 2] Accuracy, Precision, Recall, F1 score of Random Forest Classifier

Decision Tree	Red	Green	Blue
Accuracy	0.9810		
Precision	0.9777	0.9941	0.9718
Recall	0.9972	0.9630	0.9829
F1 score	0.9873	0.9929	0.9773

[표 3] CNN algorithm 모델에 기반한 정확도, 정밀도, 리콜, F1 점수

[Table 3] Accuracy, Precision, Recall, F1 score of Classifier based on CNN algorithm model

CNN algorithm	Red	Green	Blue
Accuracy	0.9991		
Precision	1.0	0.9972	1.0
Recall	0.9986	1.0	0.9986
F1 score	0.9993	0.9986	0.9993

전체적으로 합성곱 신경망 > 결정 트리 > 랜덤 포레스트 순서로 R, G, B를 잘 분류하는 것을 알 수 있었다. 또한, F1 점수를 고려할 때, R, G, B 중 상대적으로 Red를 가장 잘 분류한다고 볼 수 있다.

추가로 종합적으로 각 분류기 별 분류기 성능 평가 점수를 정리한 결과는 다음과 같다.

[표 4] roc_auc_score for Each Classifier

[Table 4] 각 분류기 별 분류기 성능 평가 점수

	Decision Tree	Random Forest	CNN algorithm
roc_auc_score	0.9961	0.9858	0.9993

분류기 성능 평가 점수를 보았을 때도 성능은 합성곱 신경망 > 결정 트리 > 랜덤 포레스트 순으로 R, G,


B를 분류하는 것을 확인할 수 있었다.

4.2 결정 트리/랜덤 포레스트/합성곱 신경망 기반 모델 오렌지 파이 수집 데이터 분류 결과 및 분석

아래 사진에서 회색의 경우는 색종이가 자르는 프레임 위치에 제대로 들어오지 못한 결과이고 주황색 상자의 경우는 잘못 분류한 것을 표시해 놓은 것이다. 사진을 보면 알 수 있듯이 세 분류 모델 모두 입력된 데이터를 R, G, B 중 하나로 예측하도록 했기 때문에 제대로 색종이를 포착하지 못한 경우에도 R, G, B 중 하나를 예측 결과로 출력한다. 이때, 색종이를 포착하지 못한 사진의 경우 우리의 눈으로는 R, G, B 중 Blue에 가장 가깝다는 생각을 할 것이다. 합성곱 신경망 모델도 마찬가지로 Blue로 예측 결과를 내놓는 것을 볼 수 있었다.

결정 트리, 랜덤 포레스트 모델의 경우는 잘못 분류하는 것도 꽤 있는 것을 확인할 수 있다. 결정 트리 모델이 잘못 예측하는 것은 랜덤 포레스트 모델에서도 똑같은 결과로 잘못하는 것을 볼 수 있었는데, 이는 R, G, B의 각 채널의 평균값을 바탕으로 예측하도록 해서 생기는 한계가 아닐까 하고 추측했다.

랜덤 포레스트 모델은 분류하는 성능이 세 모델 중에서 가장 떨어졌는데, 사진에서 볼 수 있듯이 잘못 분류하는 경우가 꽤 많은 것을 확인할 수 있었다.



[그림 5] 결정 트리(좌), 랜덤 포레스트(중앙), CNN algorithm(우) 분류모델을 사용하여 오렌지 파이로 수집한 사진 분류 결과

[Figure 5] Photo classification results collected in Orange Pi using the Decision Tree(left), Random Forest(middle), CNN algorithm(right) classification model

5. 결론

본 논문에서는 자율주행 차량이 주행하면서 얻은 이미지를 RGB의 색상을 분류하도록 고안된 여러 가지 딥러닝 모델에 각각 학습시키고, 여러 지표를 통해 모델의 성능을 평가하고 비교하였다.

앞서, 실험 결과에서 보았듯이 높은 정확도를 보이는 RGB 색상 분류 모델의 성능을 더욱 발전시킨다면, 물품 분류, 안면 인식 등 다양한 분야에서 사물이나 사람 등을 분류하는 데 큰 도움이 되리라 생각하고, 이러한 기술을 활용해서 범죄자를 빠른 시간에 체포하거나, 노동자의 과도한 근로 시간을 줄이는 것처럼 우리 주변에 존재하는 사회 문제를 해결하는데 기여할 수 있을 것이다.

또한 코딩 교육이 의무화가 되고, 인공지능(AI)이 컴퓨터공학뿐 아니라 많은 학문과 산업 분야에서 사용되며 코딩에 대한 관심이 높아지는 현 시점에서 가성비가 좋은 오렌지 파이로 모델을 만들고 여러 분야에 활용한다면, 학생들의 교육적인 측면에서 도움이 되고, 코딩에 대한 사회적 접근성도 높아지며 지식재산권의 중요성 인지 및 코딩을 통한 미래의 신지식재산권 확보를 비롯하여 사회 발전에 기여할 것으로 기대된다.

참고문헌 (References)

- [1] GreenData Lab (2022). Method And Apparatus for Predicting Agricultural Freshness, Korea Patent No.10-2448123. Korean Intellectual Property Office.
- [2] JUS.INC(2020). Styling service system and method using fashion classification code, Korea Patent No.10-0157683.Korean Intellectual Property Office.
- [3] Yohan Kim; Gyungmin Kim; Namwon An; Juman Park; Hyuk Lim. (2019). “A Feature Selection for Improving Accuracy of Deep Learning-based Network Traffic Classification” , The Journal of Korean Institute of Communications and Information Sciences, 2019, pp. 59-60.
- [4] Jaeho Yoo; Gyehe Lee. (2021). “A study on the prediction analysis of quality control components and control criteria for portuguese red wine using UCI Dataset: Focusing on the decision tree techniques by CART algorithm” , Korean Journal of Hospitality and Tourism, Vol.30, No.6, August, 2021, pp. 239-255.
- [5] Yun-Seok Ko. (2011). “The Construction Methodology of a Rule-based Expert System using CART-based Decision Tree Method” , The Journal of the Korea institute of electronic communication sciences, vol.6, no.6, December 12, 2011, pp. 849-854.
- [6] Bisong, Ekaba. (2019). “Introduction to Scikit-learn.” Building machine learning and deep learning models on Google cloud platform. Apress, Berkeley, CA, September 28, 2019, pp. 215-229.
- [7] Yo-Seob Lee; Phil-Joo Moon. (2017). “A Comparison and Analysis of Deep Learning Framework” , Volume 12 Issue 1, Korea Institute of Electronic Communication Science, February 28, 2017, pp. 115-122.